

國立陽明交通大學

光電工程學系

碩士論文

Department of Photonics

National Yang Ming Chiao Tung University

Master's Thesis

結合編碼增強因子分解機與量子退火之矽光子反向設計

Inverse Design of Silicon Photonic Structures

Using Encoding-Enhanced Factorization Machines and Quantum Annealing

研 究 生： 蔡祐昕 (Tsai, Yu Hsin)

指導教授： 吳致盛 (Wu, Jhih Sheng)

中華民國 一一五年八月

August 2026

結合編碼增強因子分解機與量子退火之矽光子反向設計

Inverse Design of Silicon Photonic Structures

Using Encoding-Enhanced Factorization Machines and Quantum Annealing

研 究 生： 蔡祐昕

Student： Yu Hsin Tsai

指導教授： 吳致盛 博士

Advisor： Dr. Jhih Sheng Wu

國立陽明交通大學

光電工程學系

碩士論文

A Thesis

Submitted to Department of Photonics

College of Electrical and Computer Engineering

National Yang Ming Chiao Tung University

in Partial Fulfillment of the Requirements

for the Degree of

Master of Science

in

Department of Photonics

August 2026

Taiwan, Republic of China

中華民國 一一五年八月

誌 謝

謝天謝地

蔡祐昕 於

國立陽明交通大學 光電工程學系

中華民國 一一五年八月



結合編碼增強因子分解機與量子退火之矽光子反向設計

學生：蔡祐昕

指導教授：吳致盛 博士

國立陽明交通大學
光電工程學系

摘 要

在過去文獻中，研究人員常使用基於梯度之伴隨方法 (Adjoint Method) 來設計光子結構。但此方法容易陷入局部最佳解，而難以探索全域最佳解。因此，本研究旨在結合機器學習與量子退火技術，並引入編碼方法以尋找全域最佳結構，為光子結構設計提供新的方法。本研究結合因子分解機 (Factorization Machines, FM) 與量子退火 (Quantum Annealing, QA) 技術，建構 FMQA 架構並應用於二維矽光子波導結構之反向設計 (Inverse Design)。

然而，受限於現有量子退火硬體之量子位元數量，本研究提出多元編碼方法，以提升設計參數之表示能力與設計空間解析度，同時也可以改善因結構離散化造成之量化誤差與階梯效應 (Staircase Effect)，確保數值模型與真實物理行為之高度一致性。在空間與特徵編碼方面，本研究具體採用了三種編碼策略：高斯上採樣 (Gaussian Upsampling)、二維傅立葉積分 (2D Fourier Integral) 以及變分自編碼器 (β -Variational Autoencoder, β -VAE)。

數值模擬的部分，本研究利用有限差分時域法 (Finite-Difference Time-Domain, FDTD) 針對橫電 (TE) 多模態在二維波導元件中之傳播行為進行分析，並將品質因子 (Figure of Merit, FoM) 設定為優化目標，以限制其低傳輸損耗，並提高傳輸效率與模態純度。

本研究設計並分析了兩種矽光子關鍵元件：90 度彎曲波導 (90-degree Bend Waveguide) 與緊湊型交叉波導 (Compact Waveguide Crossing)。在彎曲波導設計中，以降低傳

輸損耗並提升穿透率為主要目標；在緊湊型交叉波導中，則善用結構對稱性以減少量子位元需求，有效抑制模態轉換與串擾 (Crosstalk)，同時維持高傳輸效率。透過提出之 FMQA 架構與客製化目標函數，本研究成功推導出高效能且支援多模態傳輸的最佳化波導結構，為未來矽光子結構設計提供新的可能性與方向。

關鍵字：因子分解機、矽光子、波導、反向設計、量子退火、機器學習



Inverse Design of Silicon Photonic Structures Using Encoding-Enhanced Factorization Machines and Quantum Annealing

Student : Yu Hsin Tsai

Advisor: Dr. Jhih Sheng Wu

Department of Photonics
National Yang Ming Chiao Tung University

Abstract

In previous studies, researchers commonly used gradient-based adjoint methods (Adjoint Method) for the design of photonic structures. However, this method easily falls into local optima, making it difficult to explore globally optimal solutions. Therefore, this study aims to combine machine learning and quantum annealing techniques, and introduce encoding methods to search for globally optimal structures, providing a new approach for photonic structure design. This study integrates Factorization Machines (FM) and Quantum Annealing (QA) to construct an FMQA framework and applies it to the inverse design of two-dimensional silicon photonic waveguide structures.

However, due to the limited number of qubits in current quantum annealing hardware, this study proposes multi-encoding methods to enhance the representational capability of design parameters and the resolution of the design space. This approach also mitigates discretization-induced quantization errors and the staircase effect, ensuring high consistency between numerical models and real physical behavior. In terms of spatial and feature encoding, three encoding strategies are employed: Gaussian Upsampling, two-dimensional Fourier integral, and beta-Variational Autoencoder (β -VAE).

For numerical simulations, the finite-difference time-domain (FDTD) method is used to

analyze the propagation behavior of transverse electric (TE) multimodes in two-dimensional waveguide components. The figure of merit (FoM) is set as the optimization objective to constrain transmission loss and improve transmission efficiency and mode purity.

This study designs and analyzes two key silicon photonic components: a 90-degree Bend Waveguide and a Compact Waveguide Crossing. In the bend waveguide design, the primary objective is to reduce transmission loss and improve transmission efficiency. In the compact waveguide crossing, structural symmetry is exploited to reduce the number of required qubits, effectively suppress mode conversion and crosstalk while maintaining high transmission efficiency. Through the proposed FMQA framework and customized objective function, this study successfully derives high-performance optimized waveguide structures with support for multi-mode transmission, demonstrating new possibilities and directions for future silicon photonic integrated circuit design.

Keywords: Factorization Machine, Silicon Photonics, Waveguide, Inverse Design, Quantum Annealing, Machine Learning

目錄

中文摘要.....	i
英文摘要.....	iii
目錄.....	v
圖目錄.....	viii
表目錄.....	x
第一章 Introduction and Motivation	1
第二章 Related Work	4
2.1 Early Works on Inverse Design of Photonic Devices	4
2.2 FMQA/SA for Photonic Inverse Design	7
2.3 Low-dimensional Encoding-Based Methods	9
第三章 Theory	11
3.1 Optical Principles and Numerical Simulation	11
3.1.1 Waveguide Physics and Eigenmode Theory	11
3.1.2 Waveguide Discontinuities and Device Principles	19
3.1.2.1 Bend Waveguide	19
3.1.2.2 Waveguide Crossing	21
3.1.2.3 Mode Division Demultiplexer (DEMUX)	21
3.1.3 Finite-Difference Time-Domain (FDTD) Method	23
3.1.3.1 Units and Yee Lattice	23

3.1.3.2	Leapfrog Scheme and Courant Condition.....	27
3.1.3.3	Subpixel Smoothing.....	29
3.1.3.4	Perfectly Matched Layer(PML).....	30
3.1.3.5	Discrete Fourier Transform (DFT) and Mode Expansion	32
3.2	Structured Encoding and Dimensionality Reduction.....	34
3.2.1	Spatial Smoothing via Gaussian Upsampling.....	34
3.2.2	2D Fourier-Based Representation via Basis Selection	38
3.2.3	β -Variational Autoencoder for Latent Space Representation	41
3.3	Factorization Machines and Annealing Optimization	45
3.3.1	Factorization Machine-based Surrogate Model Theory	45
3.3.2	Combinatorial Optimization and QUBO Transformation	47
3.3.3	Quantum and Simulated Annealing Mechanisms.....	48
3.3.3.1	Simulated Annealing Mechanism.....	48
3.3.3.2	Quantum Annealing Mechanism	49
第四章	Method and Results.....	51
4.1	Factorization Machine with Annealing Optimization Framework.....	51
4.2	Encoding Strategies for Factorization Machine with Annealing Optimization.....	54
4.2.1	Gaussian Upsampling Strategy	55
4.2.1.1	Flowchart	55
4.2.1.2	Fabrication Constraints	56
4.2.2	2D Fourier Integral Strategy	58
4.2.3	β -Variational Autoencoder (β -VAE) Strategy	58
4.3	Mode Division Demultiplexer Optimization Results	58
4.4	Bend Waveguide Optimization Results	58

4.5 Waveguide Crossing Optimization Results	58
第五章 Conclusions.....	59
第六章 Performance Evaluation.....	60
References.....	61
第七章 Appendix 附錄.....	66



圖目錄

圖 1	波導示意圖與光場傳播方向。	12
圖 2	一維有限位能井示意圖。	14
圖 3	TE _n mode profile for $n = 0, 1, 2$	18
圖 4	彎曲波導中的模態偏移與共形映射分析。	20
圖 5	三維 Yee 晶格空間分量示意圖 [1]。	25
圖 6	二維 Yee 晶格空間分量示意圖 [1]。	26
圖 7	跳蛙法時間軸示意圖 [2]。	27
圖 8	傳統階梯化離散與次像素平滑之比較。左圖為連續幾何邊界橫切網格的原始狀態；右圖為 MEEP 於邊界網格配置等效介電常數，以改善材料介面的表示精度。[1]。	29
圖 9	PML 在非均勻介質中的失效示意圖 [1]。	31
圖 10	PML 導電率函數之離散化處理對數值反射的影響。左圖 (is_integrated=False) 因採單純點取樣而產生明顯干涉波紋；右圖 (is_integrated=True) 透過像素內精確積分，大幅消除了殘留的數值反射 [1]。	32
圖 11	二元變數矩陣示意圖。	35
圖 12	高斯上採樣後的灰階示意圖。	36
圖 13	高斯上採樣後的二元平滑化示意圖。	37
圖 14	二維頻譜係數 $\alpha_{m,n}$ 展開為二元設計向量之示意圖	39
圖 15	連續數值場 $F(x, y)$ 之示意圖	40
圖 16	由二元設計矩陣 $\rho(x, y)$ 所構成的二元矩陣即構成設計區域中的材料分布	41

圖 17	變分自編碼器的整體架構與資料流向示意圖	42
圖 18	不同的溫度參數 τ 對 Gumbel-Softmax 分布之影響示意圖	44
圖 19	Factorization Machine with Annealing Optimization 整體流程圖。	52
圖 20	高斯上採樣 (Gaussian Upsampling) 流程圖。	55
圖 21	Three simple graphs	60



表目錄

表 1	Early Works on Inverse Design of Photonic Devices	6
表 2	FMQA/SA for Photonic Inverse Design	8
表 3	Low-dimensional Encoding-Based Methods	10
表 4	MEEP unit system and practical physical unit examples.	24
表 5	不同製程限制下 Gaussian Filter 之設計參數對照表。	58

第一章、Introduction and Motivation

近年來，人工智慧 (AI) 與雲端數據中心的蓬勃發展，使得世界各地對高效能運算 (High-Performance Computing, HPC) 的算力需求迎來爆炸式的成長。然而，傳統數據中心與晶片內部的電互連架構 (Electrical Interconnects) 受限於金屬銅線歐姆損耗造成的焦耳熱 (Joule heating)、信號衰減以及頻寬瓶頸，已面臨嚴重的能源損耗與傳輸極限。為了突破這個物理限制，矽光子 (Silicon Photonics) 技術因具備高頻寬、低延遲及低功耗的光波傳輸特性，或許能成為未來取代傳統電子傳輸、實現高效能晶片資訊傳遞的關鍵技術。同時，隨著矽光子元件架構走向高密度整合，它龐大的計算參數常常面臨維度爆炸的挑戰，而近年來量子運算 (Quantum Computing) 技術的崛起，則帶給這類高維度計算難題前所未有的全新轉機。

在矽光積體電路中，為了追求更高效能並實現更密集的光路排列，透過縮小晶片尺寸來提升整合度已經成為未來趨勢，這使得緊湊型 (Compact) 光學元件的重要性也日益增加。在複雜的晶片佈局中，光訊號傳輸無法只依靠直線波導，還必須依賴彎曲波導 (Bend Waveguide) 來引導光路轉彎，並利用交叉波導 (Waveguide Crossing) 在單一層平面上實現光學的高速公路，可以避免不必要且繁瑣的繞線。然而，隨著元件尺寸縮小至微米，甚至奈米等級，彎曲波導容易因光場外偏而產生嚴重的損耗與模態串擾；交叉波導則是面臨著多模態光場散射所導致的插入損耗與通道間的信號串擾 (Crosstalk)。因此如何在極小尺寸下設計出具有低損耗與高模態光場純度的光子元件，成為目前矽光子晶片設計的瓶頸。

目前，在學術界與產業界設計矽光子元件時，主要依賴兩大類方法，第一種方法是基於傳統光學經驗與解析模型的**啟發式試誤法** (Heuristic trial-and-error Approach)。雖然

此方法可以有效設計出標準光學元件，但在面對較為複雜的光學結構時，其性能往往受限且難以預測。第二種方法則是使用當前最主流的**基於梯度的伴隨變分法** (Adjoint Method) 來進行光學結構的拓撲優化 (Topology Optimization)。此方法只需要進行一次正向電磁模擬 (Forward Simulation) 與一次伴隨模擬 (Adjoint Simulation) 即可計算出梯度，並在每次迭代中根據梯度來更新結構。然而，這種基於梯度的優化機制本質上非常容易陷入局部最佳解 (Local Minima)，且優化過程中容易產生許多細小、破碎的分支與孤島結構。這種結構不僅對製程誤差極度敏感，更常常因為結構尺寸小於最小製程極限而導致其無法通過微影與蝕刻進行量產，形成了設計與實際製造之間的巨大落差。

在過去相關文獻中，研究人員曾成功使用過因子分解機結合量子退火 (FMQA) 方法，在優化光學薄膜結構與熱發射器等相關元件的研究中都有相當顯著的成果。這啟發了我們是否也能將 FMQA 架構應用在矽光子元件設計上的構想，希望藉此解決傳統梯度演算法容易陷入局部最佳解的問題。然而，與結構單純的薄膜元件相比，二維的光學結構對幾何邊界的連續性有著更嚴格的物理要求。若使用傳統的棋盤狀像素化網格 (Pixelated Design Region) 來進行二元化 (0/1) 離散編碼，不但無法準確描述矽光子元件結構的複雜度，在 MEEP 中進行光學模擬時更容易產生階梯效應 (Staircase Effect)，導致光場產生嚴重的散射損耗。為了解決上述問題，我們引入了三種編碼技術，分別是高斯上採樣 (Gaussian Upsampling)、二維傅立葉積分 (2D Fourier Integral)、 β -變分自編碼器 (β -VAE)，透過將上述編碼技術與 FMQA 架構結合，一方面，我們可以使設計空間大幅壓縮，並且完美解決了量子退火 (Quantum Annealing) 晶片的位元連接限制，使其能夠利用少量的設計變數在適當的量子位元消耗下進行全域優化。另一方面，二元離散化的結構轉換為連續的平滑化結構，能夠使因子分解機 (Factorization Machine) 能夠更精準地學習並捕捉像素間的二階物理交互作用，透過編碼技術與 FMQA 架構的結合，不僅解決了製程中無法實現的誤差，更建立了一套兼具高製造可行性與全域搜尋實力的矽光子反向設計方法。

此研究成功結合並驗證編碼技術與 FMQA 方法的二維光學結構反向設計架構。為了驗證此方法的有效性，我們分別針對矽光子晶片中最核心的兩大基礎元件進行優化設計，分別是「90 度彎曲波導 (90-Degree Bend Waveguide)」以及「交叉波導 (Waveguide Crossing)」。本論文的核心貢獻主要歸納如下：

- 創新編碼技術結合全域優化架構: 本研究中，我們首次在編碼技術上將「高斯上採樣 (Gaussian Upsampling)」、「二維傅立葉積分 (2D Fourier Integral)」作為全新的編碼策略引入二維的光學結構反向設計領域；同時將過去研究人員用於設計空間週期性元件設計的「 β -VAE」技術應用至對邊界連續性有嚴格要求的二維矽光子波導元件上。
- 矽光基礎元件之效能優化與製程友善: 在極小尺寸的晶片設計目標下，本研究優化出具備低損耗與高模態純度的 90 度彎曲波導，以及解決模態光的拍長限制，與低插入損耗、低串擾 (Crosstalk) 的交叉波導，且邊界平滑並具備可製造性。

第二章、Related Work

Related Work 的部分，我主要會分三個部分說明，第一個部分是說明傳統早期反向設計矽光子元件的各種方法以及其說明 (Table 1)，第二個部分是探討因子分解機結合退火式演算法在光學設計上的應用以及其限制 (Table 2)，第三個部分是介紹基於生成模型與幾何編碼的降維技術 (Table 3)，並說明與本研究的關聯。

2.1 Early Works on Inverse Design of Photonic Devices

在過去二十年，矽光子元件的設計已從傳統的基於規則與經驗的設計方法，逐漸轉向自動化與最佳化的設計流程。反向設計 (Inverse Design) 的核心目標在於突破傳統幾何參數的限制，並且尋找滿足特定光學限制條件下的最佳光學結構或是最佳介電質分布。

首次將拓撲優化 (Topology Optimization, TO) 方法應用於奈米光學結構設計，是在 [3] **西元 1999 年** 由 Cox 與 Dobson 等人首次將數學模型引入二維光子晶體能隙的最大化設計中，是在光學領域將幾何微調轉向系統性材料優化的先驅。接著，[4] **西元 2004 年** Borel 等人將拓撲優化理論成功應用於半導體製程，在 SOI 基板上實現了低損耗的 Z 型光子晶體波導，驗證了演算法生成結構的物理可行性以及拓撲優化對製程誤差的容忍度。[5] **西元 2011 年** Jensen 與 Sigmund 確定了基於密度 (Density-based) 拓撲優化的標準數學模型，引入了材料插值法則以及伴隨敏感度分析 (Adjoint Sensitivity Analysis)，成為了後來基於梯度反向設計的核心原理。[6] **西元 2013 年** 由柏克萊團隊的 Lalau-Keraly 等人證明了在電磁學最佳化中，只需要一次正向模擬與一次反向伴隨模擬就可以算出

設計空間中數萬個像素的梯度，此研究帶給後續大規模、高複雜度的光學元件設計極大的貢獻。**西元 2015 年** [7] 史丹佛團隊 Piggott 等人與 [8] 猶他大學團隊 Shen 等人，分別展示了反向設計能夠在極小的面積內實現高效能的元件的能力，打破了人們對於傳統光學物理直覺的限制。[9] **西元 2016 年** Frellsen 等人針對模態分波多工器 (MDM) 的研究，凸顯了精準控制邊界條件與模態串擾的重要性。由於理論上最佳化的光學結構與製程規範之間存在一定的落差，因此在 [10] **西元 2017 年** Piggott 等人提出將微影製程限制直接轉為數學幾何約束，納入優化目標，以確保生成的結構具備實際可製造性。[11] **西元 2018 年** Molesky 等人的綜述論文則對反向設計優化光學系統的研究現況進行了系統性的總結，將這些方法視為目前矽光子元件設計的基礎。[12] **西元 2021 年** 由喬治亞理工學院與 MIT 等團隊聯合發表，建立了密度拓撲優化框架，利用可微分形態學變換 (DMT)，將工業級設計規則檢查 (DRC) 整合至優化過程中。[13] **西元 2026 年** Pao 與 Wu 等人利用拓撲優化實現了超緊湊、高 Q/V 的超緊湊奈米腔體設計，展現了在極小空間內極致的光學侷限能力。

1999	Cox/Dobson used gradient ascent in photonic crystals, laying the mathematical foundation for band gap optimization.[3]
2004	Borel/DTU first paired topology optimization with SOI fabrication, proving complex geometries are manufacturable.[4]
2011	Jensen/Sigmund (DTU) established the standard framework for density-based topology optimization and adjoint analysis.[5]
2013	Lalau-Keraly/UC Berkeley paired adjoint and level-set methods, breaking bottlenecks for large-scale electromagnetic design.[6]
2015	Stanford's Piggott used inverse design for an ultra-compact demultiplexer, breaking physical intuition[7], Utah's Shen debuted DBS discrete optimization for a tiny PBS, launching the pixelated design school.[8]
2016	Frellsen/DTU applied topology optimization to mode-division multiplexing, overcoming high-order mode crosstalk bottlenecks.[9]
2017	Piggott/Stanford embedded lithographic constraints into the algorithm, enabling direct interface with commercial foundries.[10]
2018	Molesky/Stanford joint team published an authoritative review outlining the landscape of nanophotonic inverse design.[11]
2021	Hammond/Georgia Tech/MIT used differentiable transformations to embed foundry DRC rules, bridging theory and mass production.[12]
2026	Pao utilized topology optimization to achieve ultra-compact, high Q/V nanocavities, overcoming reliance on large-area periodic structures.[13]

TABLE 1: Early Works on Inverse Design of Photonic Devices

2.2 FMQA/SA for Photonic Inverse Design

為了克服連續優化方法中非凸 (Non-convex) 邊界投影導致的數值不穩定性，研究逐漸轉向「離散組合優化 (Combinatorial Optimization)」。此方法將光學元件或結構參數映射為離散的二元陣列 (Binary Array)，並藉由退火型演算法進行全域搜尋，以避開光學設計中易陷入局部最小值 (Local Minima) 的瓶頸。

[14] **西元 1983 年** Kirkpatrick 等人提出「模擬退火 (Simulated Annealing, SA) 演算法」，將熱力學退火概念轉化為數學模型，藉由隨機選擇與允許機率性攀爬能量障壁的機制突破局部最佳解，成為組合優化理論與後續啟發式全域搜尋演算法的基礎。[15] **西元 1998 年** Kadowaki 與 Nishimori 提出量子退火 (Quantum Annealing, QA) 理論，奠定尋找 Ising/QUBO 能量基態的物理基礎，利用量子穿隧效應或機率性躍遷跨越複雜設計空間中的局部極小值。[16] **西元 2010 年** Rendle 提出「因子分解機 (Factorization Machines, FM)」，其數學表達式可直接映射為 QUBO 模型的二次多項式，將高維組合問題轉換為 QUBO 形式，使直接利用退火硬體加速最佳化成為可能。[8] **西元 2015 年** Shen 與 Menon 等人提出「直接二元搜尋法 (Direct Binary Search, DBS)」，無需量子計算設備即可利用二元像素化結構實現高效的光學元件設計。[17] **西元 2020 年** Kitai 與 Tamura 等東京大學團隊結合因子分解機與 D-Wave 量子退火硬體，提出 FMQA 架構，於超穎材料設計中突破了傳統物理直覺的限制。[18] **西元 2022 年** Inoue 與 Noda 等京都大學團隊將 FMQA 應用於 PCSEL 設計，驗證了該架構處理複雜非均勻結構與高維離散參數的有效性。[19] **西元 2024 年** Zhu 與 Li 等人的綜述確立了「代理模型結合退火 (Surrogate Model + Annealing)」混合架構在複雜物理反向設計中的可靠性與高效性。[20] **西元 2025 年** Hu 與 Wu 等人成功將 FMQA 架構應用於薄膜濾波器與類條碼超穎結構等實務設計上，不僅解決了光學長程干涉與二次耦合限制的衝突，更驗證了該架構在微納光學元件上的強大逆向設計能力。[21] **西元 2026 年** Chang 與 Wu 等人進一步建立了一套結合

機器學習與退火演算法的通用設計框架，並應用於超振盪透鏡（SOL）的反向設計，成功打破了小焦點與高旁瓣的權衡難題，為量子相容的光學元件設計鋪平了道路。

1983	Kirkpatrick/IBM introduced Simulated Annealing (SA), providing a thermodynamic basis for overcoming local optima.[14]
1998	Kadowaki/Nishimori proved Quantum Annealing (QA) outpaces SA via tunneling, forming the theoretical bedrock for Ising/QUBO hardware.[15]
2010	Rendle introduced Factorization Machines (FM), a key mathematical bridge for mapping complex functions into QUBO matrices.[16]
2015	Stanford's Piggott built an ultra-compact demultiplexer; meanwhile, Utah's Shen debuted DBS optimization to launch the pixelated design school.[7, 8]
2020	Kitai/University of Tokyo team pioneered FMQA, creating a closed-loop "ML + D-Wave QA" framework for metamaterial discovery.[17]
2022	Inoue/Kyoto University team applied FMQA to PCSELs, breaking trade-offs in output power and divergence angles.[18]
2024	Zhu/Chemical Reviews published a comprehensive review endorsing the "surrogate model + annealing" paradigm for inverse design.[19]
2025	Hu applied the FMQA framework to optical filters and metastructures, resolving conflicts between long-range interference and quadratic coupling.[20]
2026	Chang established a universal ML-annealing framework for superoscillatory lenses, overcoming the small-focus and high-sidelobe trade-off.[21]

TABLE 2: FMQA/SA for Photonic Inverse Design

2.3 Low-dimensional Encoding-Based Methods

為了解決組合最佳化演算法在高解析度網格下量子位元 (Qubits) 不足的問題，並降低離散像素結構造成的製程鋸齒與光學散射損耗，本研究引入潛在空間降維及空間頻率平滑化機制。為奠定此編碼架構的理論基礎，以下整理相關技術的發展脈絡。

[22] 西元 2011 年 Lazarov 與 Sigmund 為消除拓撲優化中的棋盤格效應 (checkerboard effect)，引入基於 Helmholtz 偏微分方程式的濾波算子，透過隱式求解達到低通濾波效果。[23] 西元 2016 年 Odena 等人指出，神經網路使用反卷積 (deconvolution) 放大幾何訊號時，常因網格不均勻重疊產生棋盤格邊界偽影，而研究證實，改用「插值放大搭配標準卷積 (resize-convolution)」能有效消除網格瑕疵並還原平滑邊界。同年，[24] Shi 等人提出次像素卷積 (sub-pixel convolution) 超解析度技術，透過重組特徵圖空間維度，直接將低解析度特徵映射為高解析度輸出。西元 2017 年 [25] Higgins 等人提出 β -VAE 架構，藉由超參數 β 限制潛在空間容量，並於損失函數引入 KL 散度懲罰項以控制潛在空間自由度。同年，[10] Piggott 與 Vučković 等人在光學反向設計中採用水平集方法 (level set method) 描述結構邊界，並加入曲率限制以消除細縫與孤島，提升波導邊界平滑度與製程可行性。西元 2018 年 [26] Burgess 等人提出容量退火 (capacity annealing)，改善了 β -VAE 在特徵解耦與重建精度間的取捨，優化低維潛在空間的表示能力。西元 2019 年 [27] Ma 與 Liu 等人將 VAE 應用於超穎材料的反向設計。同年，[28] Zhang 等人指出卷積網路縮放影像時易產生混疊 (aliasing) 而導致特徵不穩定，證實引入低通濾波可緩解此現象，為上採樣 (upsampling) 階段的高斯平滑提供理論支持。西元 2020 年 [29] Li 與 Anandkumar 等人提出傅立葉神經算子 (FNO)，以低頻參數化實現偏微分方程式映射的網格獨立性，並支持利用傅立葉轉換平滑幾何邊界。西元 2021 年 [30] Kudyshev 與 Liao 等人結合對抗式自編碼器 (AAE) 與全域最佳化，於低維潛在空間中搜索最佳結構，顯著縮減高維設計的運算開銷。同年，[31] Karras 等人與 NVIDIA 團隊發表 StyleGAN3，

藉由抗混疊設計抑制網格偽影，生成更平滑穩定的幾何圖樣。

2011	Lazarov/Sigmund introduced Helmholtz PDE filtering, eliminating checkerboard effects and mesh-dependence in topology optimization.[22]
2016	Odena/Distill proposed Resize-Convolution to replace deconvolution, eliminating grid artifacts for smooth boundaries; meanwhile[23], Shi/CVPR debuted Sub-pixel Convolution, achieving real-time high-definition super-resolution.[24]
2017	Higgins/DeepMind introduced β -VAE for feature disentanglement to fit hardware bit limits[25]; Piggott/Stanford used level-set methods with curvature constraints to smooth boundaries for foundry compatibility.[10]
2018	Burgess/DeepMind introduced Capacity Annealing in β -VAEs, breaking the trade-off between disentanglement and reconstruction.[26]
2019	Ma/Advanced Materials applied VAEs to metamaterials for dimension reduction, resolving the physical pain point of one-to-many mapping.[27]; Zhang/ICML introduced anti-aliasing low-pass filters to CNNs, restoring shift-invariance and supporting Gaussian smoothing.[28]
2020	Li/ICLR pioneered Fourier Neural Operators (FNO) for mesh-independent PDE learning, supporting continuous geometric optimization.[29];
2021	Kudyshev/Nanophotonics used AAE dimension reduction to couple generative models with black-box global optimization engines.[30]; Karras/NVIDIA introduced StyleGAN3, treating feature maps as continuous signals with low-pass filters to eliminate aliasing.[31]

TABLE 3: Low-dimensional Encoding-Based Methods

第三章、Theory

3.1 Optical Principles and Numerical Simulation

在這個章節中，我會詳細推導並說明光在矽基整合光學波導中的傳播物理，以及模態分波解多工器運作的理論基礎，最後會介紹數值模擬的基礎理論。我們將從電磁場數學模型出發，分析奈米級波導的邊界條件與模態行為，作為後續反向設計演算法與模型預測的依據。

3.1.1 Waveguide Physics and Eigenmode Theory

首先，在波導中，光會被侷限在折射率較高的矽核心中，並透過全反射 (Total internal reflection, TIR) 進行傳播。關於介電質波導中電磁場行為與模態特徵值問題的完整理論架構，本節主要參考 A. Yariv 的經典著作 [32] 所建立的物理模型。在無自由電荷 ($\rho = 0$) 且無源 ($\vec{J} = 0$) 的介電質波導環境中，我們可以用馬克士威方程 (Maxwell equations) 中的法拉第電磁感應定律(3.1)與馬克士威-安培定律(3.2)微分式來描述光的傳播行為，如下所示：

$$\nabla \times \vec{E} = -\frac{\partial \vec{B}}{\partial t} \quad (3.1)$$

$$\nabla \times \vec{H} = \frac{\partial \vec{D}}{\partial t} \quad (3.2)$$

這時候引入了材料的介電質 (ϵ) 和導磁率 (μ)，假設光場在具有時諧性 (Time-Harmonic)，則(3.1)和(3.2) 馬克士威方程可以寫成頻域複數形式：

$$\nabla \times \vec{E} = -i\omega\mu\vec{H} \quad (3.3)$$

$$\nabla \times \vec{H} = i\omega\epsilon\vec{E} \quad (3.4)$$

接著，我們再對馬克士威方程頻域複數形式(3.3)與(3.4)取旋度，再均勻的介質中，由於 $\nabla \cdot \vec{E} = 0$ ，因此，我們即可推導出經典的亥姆霍茲方程 (Helmholtz Equation):

$$\nabla^2 \vec{E} + k_0^2 n^2(\vec{r}) \vec{E} = 0 \quad (3.5)$$

其中， $k_0 = \frac{\omega}{c}$ 為真空中的波數，介電常數與折射率 (n) 關係為 $\epsilon = n^2\epsilon_0$ ，因此光子能夠被侷限在波導內部傳播，就是因為波導核心層與包層之間的折射率差而產生的全反射 (TIR)，在本篇矽基波導的核心材料為矽 (Silicon, Si)，其折射率 (n_{Si}) 約為 3.48; 而包層為二氧化矽 (Silicon dioxide, SiO_2)，其折射率 (n_{SiO_2}) 約為 1.44，如圖 1 所示。




圖 1: 波導示意圖與光場傳播方向。

當波導結構在傳播方向 (z 軸) 上具備平移對稱性 (Translation symmetry) 時，我們可

以透過將電場進行解分離變數，寫成沿著 z 方向傳播的形式：

$$\vec{E} = \vec{E}(x, y)e^{-i\beta z} \quad (3.6)$$

接著將 z 方向傳播形式(3.6)帶入亥姆霍茲方程(3.5)後，對 z 做二次偏微分會得到 $-\beta^2$ (也就是 $\frac{\partial^2}{\partial z^2} \rightarrow -\beta^2$)，整理後我們可以得到橫截面 (xy 平面) 上的二維波動方程：

$$\left(\frac{\partial^2}{\partial x^2} + \frac{\partial^2}{\partial y^2} \right) \vec{E} + k_0^2 n^2(\vec{r}) \vec{E} = \beta^2 \vec{E} \quad (3.7)$$

這邊可以定義成一個線性算子 (Linear operator) L ：

$$L \triangleq \left(\frac{\partial^2}{\partial x^2} + \frac{\partial^2}{\partial y^2} \right) + k_0^2 n^2(\vec{r}) \quad (3.8)$$

因此可以將整個光學波導的模態傳播問題簡化為標準的特徵值問題 (Eigenvalue Problem, EVP)：

$$L\vec{E} = \beta^2 \vec{E} \quad (3.9)$$

在這個式子中，模態 (Modes) 的空間場分佈就會等於該算子 L 的特徵函數 (Eigenfunction)，而傳播常數的平方 β^2 則會等於其對應的特徵值 (Eigenvalue)。這個光學特徵值問題在數學形式上，與量子力學中的一維有限位能井問題 (Particle in a box problem)(圖 2) 有著異曲同工之妙，都必須在邊界條件下求得特定波數與對應的空間分布，一維定態薛丁格方程 (Schrödinger equation) 表示如下：

$$-\frac{\hbar^2}{2m} \nabla^2 \psi + V(\vec{r})\psi = E\psi \quad (3.10)$$

此式的波函數 (ψ)、位能分布 ($V(\vec{r})$) 與能量特徵值 (E)，分別對應到了波導方程(3.7)中的電場 ($\vec{E}$)、折射率分布 ($k_0^2 n^2(\vec{r})$) 以及傳播常數的平方 (β^2)。在數學形式的對等性中，我們可以得出光波導兩個核心物理特質的結論：模態量子化 (Quantization) 與能量侷限性 (Confinement)，只有特定且不連續的 β 值才能夠穩定存在於波導中，且折射率的對比愈大，位能井就愈深，則波導對光場的侷限性就越好。




圖 2: 一維有限位能井示意圖。

另外，每個模態的傳播特徵可以由有效折射率 (Effective Refractive Index) 來定義：

$$n_{eff} \triangleq \frac{\beta}{k_0} \quad (3.11)$$

因此，對於能夠在波導中穩定傳播的束縛模態，其有效折射率 (n_{eff}) 必須介於核心折射率 (n_2) 和包層折射率 (n_1) 之間，也就是，

$$n_1 < n_{eff} < n_2 \quad (3.12)$$

其原因可由電磁場在核心層與包層中的分布特性來理解。在核心層內，光場必須呈現

簡諧波解 (Sinusoidal solution) 傳播，因此橫向波數需滿足

$$h^2 \triangleq k_0^2 n_2^2 - \beta^2 > 0 \quad (3.13)$$

由此可得 $\beta < n_2 k_0$ ，也就是 $n_{eff} < n_2$ 。另一方面，在包層中光場需以指數衰減的形式向外傳播，也就是漸逝場 (Evanescent Field) 的形式向外衰減，以確保光能量被侷限於波導內，因此衰減係數必須滿足

$$q^2 = \beta^2 - k_0^2 n_1^2 > 0 \quad (3.14)$$

由此可得 $\beta > n_1 k_0$ ，也就是 $n_{eff} > n_1$ 。因此，束縛模態的有效折射率必須介於核心層與包層折射率之間，即使是結構較為複雜的反向設計波導，仍然需要滿足以上條件。

接著，本節參考 A. Yariv 經典光電物理模型中所建立的分析架構 [32]，以一維平板波導 (Slab Waveguide) 結構為例，考慮只有具備 y 軸分量的橫電模態 (Transverse Electric Modes, TE modes)，其電場可以由以下公式表示：

$$E_y(x, z, t) = E_m(x) e^{i(\omega t - \beta z)} \quad (3.15)$$

代入二維波動方程(3.7)可以簡化為一維常微分方程，如下式所示：

$$\frac{d^2}{dx^2} E_m + [k_0^2 n^2(x) - \beta^2] E_m = 0 \quad (3.16)$$

其中，核心層與包層之折射率分布表示如下：

$$n(x) = \begin{cases} n_1, & |x| \geq \frac{d}{2} \\ n_2, & |x| < \frac{d}{2} \end{cases} \quad (3.17)$$

由於平板波導的幾何結構在中心軸 ($x=0$) 具有對稱性，因此特徵解可以解為偶對稱 (Symmetric) 與奇對稱 (Anti-Symmetric) 的解，其電場特徵函數 $E_m(x)$ 表示如下：

- 偶對稱模態 (如 TE_0, TE_2):

$$E_m(x) = \begin{cases} C \cos(hx), & |x| < \frac{d}{2} \\ B e^{-q|x|}, & |x| \geq \frac{d}{2} \end{cases} \quad (3.18)$$

- 奇對稱模態 (如 TE_1, TE_3):

$$E_m(x) = \begin{cases} C \sin(hx) \cdot \text{sgn}(x), & |x| < \frac{d}{2} \\ B e^{-q|x|} \cdot \text{sgn}(x), & |x| \geq \frac{d}{2} \end{cases} \quad (3.19)$$

此處橫向波數 $h^2 \triangleq k_0^2 n_2^2 - \beta^2 > 0$ 且包層消散係數 $q^2 \triangleq \beta^2 - k_0^2 n_1^2 > 0$ 。

根據電磁學邊界條件，在介電質交界面 ($x = \pm d/2$) 上，切線電場分量 E_y 與切線磁場分量 H_z 皆必須滿足連續條件。透過法拉第電磁感應定律可導出磁場分量關係式

$H_z = \frac{1}{-i\omega\mu} \frac{\partial E_y}{\partial x}$ 。將兩者的電場解代入並應用 $x = d/2$ 處的連續條件，可分別得到對應

的齊次線性方程組：

- 偶對稱邊界條件:

$$Be^{-q\frac{d}{2}} - C \cos\left(h\frac{d}{2}\right) = 0 \quad (3.20)$$

$$Bqe^{-q\frac{d}{2}} - Ch \sin\left(h\frac{d}{2}\right) = 0 \quad (3.21)$$

- 奇對稱邊界條件:

$$Be^{-q\frac{d}{2}} - C \sin\left(h\frac{d}{2}\right) = 0 \quad (3.22)$$

$$Bqe^{-q\frac{d}{2}} + Ch \cos\left(h\frac{d}{2}\right) = 0 \quad (3.23)$$

若要使上述方程組存在非平凡解 (Nontrivial solutions)，其係數矩陣的行列式值必須嚴格等於零。展開行列式並消去共同項 $e^{-qd/2}$ 後，即可成功導出兩種模態的特徵方程式 (Characteristic Equations):

$$\text{Symmetric (偶對稱): } q = h \tan\left(\frac{hd}{2}\right) \quad (3.24)$$


$$\text{Anti-symmetric (奇對稱): } q = -h \cot\left(\frac{hd}{2}\right)$$

將 h 與 q 的定義代回上式(3.24)，即可得到最終用來求解傳播常數 β 的物理關係式:


$$\text{Symmetric: } \sqrt{\beta^2 - k_0^2 n_1^2} = \sqrt{k_0^2 n_2^2 - \beta^2} \tan\left[\sqrt{k_0^2 n_2^2 - \beta^2} \frac{d}{2}\right] \quad (3.25)$$

$$\text{Anti-symmetric: } \sqrt{\beta^2 - k_0^2 n_1^2} = -\sqrt{k_0^2 n_2^2 - \beta^2} \cot\left[\sqrt{k_0^2 n_2^2 - \beta^2} \frac{d}{2}\right]$$


在實際的光電工程分析中，此方程式(3.25)可以藉由數值分析工具來進行求解，來計算各階模態精確解的特徵值 β ，以此來描繪出如 TE_0, TE_1, TE_2 等完整模態橫向波函數分佈，如圖 3 所示。



(a) TE₀ Mode Profile



(b) TE₁ Mode Profile



(c) TE₂ Mode Profile

圖 3: TE_n mode profile for $n = 0, 1, 2$

3.1.2 Waveguide Discontinuities and Device Principles

理想直波導具有沿傳播方向 (z 軸) 的平移對稱性，其特徵模態相互正交。然而，矽基光電積體電路 (PIC) 常需引入彎曲、交叉或多模複合等不連續結構 (Waveguide Discontinuities) 以實現光信號路由與多工。這些結構打破了平移對稱性，進而引起散射、輻射及模態間的能量耦合。本節將分析彎曲波導、交叉波導與模態分波解多工器的物理原理與設計限制。

3.1.2.1 Bend Waveguide

當光場進入高曲率的 90 度彎曲波導時，等相位面會因曲率而偏轉。為維持波前同步，外側等相位面的相速度須隨半徑線性增加。當外側相速度超過包層介質的相速度極限 (c/n_{clad} 或 c/n_1) 時，光場無法滿足全反射條件，從而轉化為散射光場並產生散射損耗。

此空間形變與損耗可藉由 Heiblum 與 Harris 提出的共形映射 (Conformal Transformation) 理論來描述 [33]。透過映射函數 $W = u + iv = R \ln(Z/R)$ (其中 $Z = x + iy$, R 為等效彎曲半徑)，彎曲波導可轉換為 u, v 平面上的等效直波導。在該坐標系下，波導的等效折射率 $n_{\text{eq}}(u)$ 分佈為：

$$n_{\text{eq}}^2(u) = n^2(u) \exp\left(\frac{2u}{R}\right) \approx n^2(u) \left(1 + \frac{2u}{R}\right) \quad (3.26)$$

公式顯示，波導外側 ($u > 0$) 的等效折射率隨 u 線性增加，如圖 4(b) 所示。此折射率梯度使光場中心向外側偏移 (Mode Shift)，導致直波導與彎曲波導銜接時產生模態不匹配損耗 (Mode Mismatch Loss)。

利用 WKB 近似 (Wentzel-Kramers-Brillouin Approximation) 求解此等效模型，可推導出彎曲波導的散射損耗衰減常數 α 。在微擾近似下， α 主要由穿透轉折點 (Turning

Point，即 $n_{\text{eq}}(u) = n_{\text{eff}}$ ，如圖 4(b)) 外側之勢壘決定，其正比關係可近似為：

$$\alpha \propto \exp\left(-\frac{4\pi}{\lambda_0} R n_{\text{clad}} \delta\right) \quad (3.27)$$

為了提高 TE_0 模態的耦合效率，傳統設計通常會採用向外平移 (Outward Offset, Δx ，如圖 4(a)) 技術來對齊銜接處的場型中心。而當元件尺寸為了提高集成度而大幅縮小時，彎曲半徑 R 的減小會導致散射損耗 α 指數型激增。此時，傳統的固定半徑與線性平移設計已無法有效兼顧散射損耗與模態不匹配。因此，本研究採用反向設計方法，對彎曲波導的幾何邊界進行非對稱的結構優化，以突破傳統結構的設計瓶頸。

如圖 4 所示，(a) 實體空間中，彎曲波導的模態中心向外側偏移，而直、彎波導銜接處可以利用向外平移的方式來對齊光場中心；(b) 共形映射後，等效直角坐標 u 下的折射率與模態場 $\psi(u)$ 分佈。等效折射率 $n_{\text{eq}}(u)$ 隨空間往外側增加，在轉折點 (Turning Point, $n_{\text{eq}} = n_{\text{eff}}$) 外側，光場轉化為振盪的輻射模並造成散射損耗。




圖 4: 彎曲波導中的模態偏移與共形映射分析。

3.1.2.2 Waveguide Crossing

在交叉波導 (Waveguide Crossing) 結構中，幾何不連續性主要發生於十字交會處。當原本被束縛在輸入波導的特徵模態進入波導交叉處時，會因為瞬間失去了側邊高折射率差的約束，而光場會衰減為在均勻介質中傳播的自由空間波 (Free-space wave)，進而遵循惠更斯-菲涅耳原理 (Huygens-Fresnel Principle)，產生明顯的繞射與發散。

當發散的光場抵達輸出端時，傳輸效率 η 在數學上受限於輸入發散場 $\vec{E}_{in}$ 與輸出波導特徵模態 $\vec{E}_{out}$ 之間的重疊積分 (Overlap integral)[34]:

$$\eta = \frac{\left| \iint \vec{E}_{in} \times \vec{H}_{out}^* \cdot \hat{z} dx dy \right|^2}{\iint \text{Re}(\vec{E}_{in} \times \vec{H}_{in}^*) \cdot \hat{z} dx dy \iint \text{Re}(\vec{E}_{out} \times \vec{H}_{out}^*) \cdot \hat{z} dx dy} \quad (3.28)$$

沒有約束的繞射效應會使輸入場 $\vec{E}_{in}$ 在空間中快速的發散，而導致上述重疊積分大幅下降，成為元件插入損耗 (Insertion Loss) 的主因。

這些未與輸出特徵模態匹配的雜散光場，除了部分向基板與包層發散外，大部分會直接散射並耦合至垂直的交叉通道。這種能量洩漏會導致通道間串擾 (Crosstalk) 與訊號交叉污染，進而降低積體光學系統的訊號雜訊比 (Signal-to-Noise Ratio, SNR) 與雜訊容限 (Noise Margin)。

3.1.2.3 Mode Division Demultiplexer (DEMUX)

模態分波解多工器 (Mode Division Demultiplexer, DEMUX) 用於將單一多模通道中同時傳輸的不同階模態 (如 TE_0 與 TE_1) 分離，並轉換為對應單模輸出通道的基模。根據勞倫茲互易定理 (Lorentz Reciprocity)，光的傳播具有可逆性，因此模態分波多工器 (MUX) 與解多工器 (DEMUX) 在物理結構上完全相同，只有傳播方向相反。

在理想的直波導中，各階模態構成完備且正交 (Orthogonal) 的基底，模態能量互不干擾。若要使特定高階模態發生空間轉移與轉換，解多工器就必須引入非對稱幾何邊

界或拓撲突變。這些細小破碎的結構微擾會打破原有的系統對稱性，使原本的正交性失效。這種模態轉換與非預期的能量耦合可以用耦合模態理論 (Coupled Mode Theory, CMT)[32] 分析。假設多模波導中的高階模態為 a (傳播常數為 β_a)，目標單模波導中的基模為 b (傳播常數為 β_b)，則兩通道間的能量轉移滿足以下耦合微分方程：

$$\frac{dA(z)}{dz} = -i\kappa_{ab}B(z)e^{i\Delta\beta z} \quad (3.29)$$

$$\frac{dB(z)}{dz} = -i\kappa_{ba}A(z)e^{-i\Delta\beta z} \quad (3.30)$$

其中， $A(z)$ 與 $B(z)$ 分別為兩模態沿傳播方向的包絡 (Envelope)，相位失配量定義為 $\Delta\beta = \beta_a - \beta_b$ 。

若要使能量完全轉移，必須滿足相位匹配條件 (Phase Matching, $\Delta\beta = 0$)。在此基礎上，引入非對稱幾何微擾 $\Delta\epsilon(x, y)$ 後，模態間的交叉耦合係數 (Cross-coupling coefficient) [32] κ_{ab} 可表示為微擾區域的重疊積分：

$$\kappa_{ab} = \frac{\omega}{4} \iint \Delta\epsilon(x, y) \vec{E}_a^* \cdot \vec{E}_b dx dy \quad (3.31)$$

傳統非對稱的直接耦合器受限於簡單的幾何漸變，容易產生非理想的物理效應。當解多工器引入拓撲突變時，非預期的能量耦合會隨之增強。若非目標模態在微擾區域內的耦合係數 κ_{mn} 不為零，部分能量會洩漏到其他分離通道，造成通道間的串擾 (Crosstalk, CT)。其串擾定義為：

$$CT \text{ (dB)} = 10 \log_{10} \left(\frac{P_{\text{leakage}}}{P_{\text{target}}} \right) \quad (3.32)$$

其中 P_{leakage} 為洩漏功率， P_{target} 為目標通道功率。

此外，元件的插入損耗 (Insertion Loss, IL) 用以描述輸入光功率與目標輸出通道功率

之間的損失，其定義為

$$IL \text{ (dB)} = -10 \log_{10} \left(\frac{P_{\text{target}}}{P_{\text{in}}} \right) \quad (3.33)$$

其中 P_{in} 為輸入光功率。插入損耗愈小，表示元件的能量傳輸效率愈高。高串擾會降低系統的訊號雜訊比 (Signal-to-Noise Ratio, SNR)，而未成功耦合到目標通道的能量則會增加元件的插入損耗。

因此，由於模態解多工器具有複雜且微細的幾何特徵，且各結構參數對光場分佈與模態耦合存在高度非線性的交互作用，難以透過傳統參數掃描或經驗法則進行設計。為此，本研究採用反向設計 (Inverse Design) 方法，利用最佳化演算法在龐大的設計空間中自動搜尋符合性能需求的結構。

3.1.3 Finite-Difference Time-Domain (FDTD) Method

本篇論文所使用的光學模擬方法為 MEEP (MIT Electromagnetic Equation Propagation)，是由 MIT 麻省理工學院的研究團隊於 2006 年開發的開源電磁模擬軟體，其方法基於有限差分時域法 (Finite-Difference Time-Domain, FDTD)。本章節內容主要參考其研究團隊於 2010 年發表的論文 [35] 以及其官方網站的說明 [1]

3.1.3.1 Units and Yee Lattice

在 MEEP 中，所有物理量皆採用無因次單位 (Dimensionless Units)，將基礎物理常數設定為 $\epsilon_0 = 1$ 、 $\mu_0 = 1$ 以及光速 $c = 1$ 。在此單位制下，馬克士威旋度方程 (Maxwell's Curl Equations) 化為無因次形式：

$$\nabla \times E = -\frac{\partial H}{\partial t} \quad (3.34)$$

$$\nabla \times H = \varepsilon_r(r) \frac{\partial E}{\partial t} \quad (3.35)$$

其中 $\varepsilon_r(r)$ 為相對介電常數。這種單位制的直接結果是：當空間幾何結構與工作波長等比例縮放時，電磁響應完全不變，即馬克士威方程的尺度不變性 (Scale Invariance)。實際應用中，使用者可自定義一個特徵長度單位 a ，其他物理量單位由 a 與 c 推導得出，對應關係如下表所示：

物理量 (Physical Quantity)	MEEP 單位表示	實際物理單位 ($a = 1 \mu\text{m}$)
長度 (Length, L)	a	$1 \mu\text{m}$
時間 (Time, T)	a/c	3.33 fs
頻率 (Frequency, f)	c/a	300 THz
波長 (Wavelength, λ)	a/f_{MEEP}	$\lambda = 1/f_{\text{MEEP}}$

TABLE 4: MEEP unit system and practical physical unit examples.

例如，MEEP 中設定頻率 $f_{\text{MEEP}} = 0.5$ 時，對應的實際工作波長為 $\lambda = a/0.5 = 2a$ 。

空間離散化方面，MEEP 採用 Yee 晶格 (Yee Grid) 技術。如圖 5 所示，Yee 晶格的核心做法是將電場 E 與磁場 H 的空間分量在網格中錯開半個步長 ($\Delta/2$) 交替排列。以三維網格點 (i, j, k) 為基準，各場分量的取樣位置具有嚴格的幾何對稱性：電場分量位於稜邊中心，例如 E_x 位於 $(i + 1/2, j, k)$ ；磁場分量則位於面中心，例如頂面的磁場分量 H_z 位於 $(i + 1/2, j + 1/2, k + 1)$ 。這種交錯排布使得空間偏導數可以用中心差分 (Central-difference) 近似，具有二階精確度，可有效降低數值色散誤差。以頂面最前側稜邊的電場 $E_x(i + 1/2, j, k + 1)$ 位置為例，這邊的 $\partial H_z / \partial y$ 空間偏導數可近似表示為：

$$\left. \frac{\partial H_z}{\partial y} \right|_{(i+1/2, j, k+1)} \approx \frac{H_z(i + 1/2, j + 1/2, k + 1) - H_z(i + 1/2, j - 1/2, k + 1)}{\Delta y} \quad (3.36)$$




圖 5: 三維 Yee 晶格空間分量示意圖 [1]。

本研究之元件數值模擬主要採用二維結構，假設幾何結構在 z 軸無限延伸 ($\partial/\partial z = 0$)。在此假設下，馬克士威旋度方程可化簡為兩組對應 TE 與 TM 偏振的方程式。

- TE 模態 (Transverse Electric)：包含場分量 E_x 、 E_y 與 H_z ，方程式簡化為：

$$\frac{\partial E_y}{\partial x} - \frac{\partial E_x}{\partial y} = -\frac{\partial H_z}{\partial t} \quad (3.37)$$

$$\frac{\partial H_z}{\partial y} = \varepsilon \frac{\partial E_x}{\partial t}, \quad -\frac{\partial H_z}{\partial x} = \varepsilon \frac{\partial E_y}{\partial t} \quad (3.38)$$

- TM 模態 (Transverse Magnetic)：包含場分量 H_x 、 H_y 與 E_z ，方程式簡化為：

$$\frac{\partial H_y}{\partial x} - \frac{\partial H_x}{\partial y} = \varepsilon \frac{\partial E_z}{\partial t} \quad (3.39)$$

$$\frac{\partial E_z}{\partial y} = -\frac{\partial H_x}{\partial t}, \quad -\frac{\partial E_z}{\partial x} = -\frac{\partial H_y}{\partial t} \quad (3.40)$$

上述方程映射回二維的 Yee 晶格時，三維網格可簡化為 xy 平面上的二維網格。以本研

究反向設計之光學模擬所涉及的 TE 模態為例，其二維 Yee 晶格分量配置如圖 6 所示。

在二維網格點 (i, j) 的標準下：

- 磁場分量 H_z 位於網格胞體 (Cell) 之中心點，位置為 $(i + 1/2, j + 1/2)$ 。
- 電場分量 E_x 與 E_y 則分別位於網格的水平與垂直稜邊中點，位置分別為 $(i + 1/2, j)$ 與 $(i, j + 1/2)$ 。

藉由這種二維交錯排列，在公式(3.38) 中計算 E_x 更新所需的 $\partial H_z / \partial y$ 空間偏導數，在網格點 $(i + 1/2, j)$ 處可以精確的離散化為：

$$\left. \frac{\partial H_z}{\partial y} \right|_{(i+1/2, j)} \approx \frac{H_z(i + 1/2, j + 1/2) - H_z(i + 1/2, j - 1/2)}{\Delta y} \quad (3.41)$$

上述的偏振分離與二維離散化特性，可以減少二維模擬中的記憶體使用和計算成本




圖 6: 二維 Yee 晶格空間分量示意圖 [1]。

3.1.3.2 Leapfrog Scheme and Courant Condition

除了在空間上使用 Yee 晶格進行交錯排列外，FDTD 方法在時間軸上也採用了這種類似的交錯取樣策略，稱為跳蛙法 (Leapfrog Scheme)。如圖 7 所示，電場 E 在整數時間步長 $t = n\Delta t$ 取樣（如 E^n, E^{n+1} ），而磁場 H 則在半整數時間的步長 $t = (n + 1/2)\Delta t$ 取樣（如 $H^{n-1/2}, H^{n+1/2}$ ）。




圖 7: 跳蛙法時間軸示意圖 [2]。

藉由錯開在時間軸上的半步長，使得馬克士威方程中的時間偏導數都能夠以二階精確度的中心差分進行近似計算。以二維 TE 模態中的公式(3.38)為例，電場 E_x 在時間 $t = (n + 1/2)\Delta t$ 的時間偏導數可利用中心差分近似為：

$$\left. \frac{\partial E_x}{\partial t} \right|_{(i+1/2, j)}^{n+1/2} \approx \frac{E_x^{n+1}(i + 1/2, j) - E_x^n(i + 1/2, j)}{\Delta t} \quad (3.42)$$

將公式(3.41) 與公式(3.42) 代回原方程式(3.38)，就可以推導出電場在未來時間步長 $n + 1$ 的顯式更新方程式 (Explicit Update Equation)，在更新位置 $(i + \frac{1}{2}, j)$ 處，電場更新

方程式可簡寫為：

$$E_x^{n+1} = E_x^n + \frac{\Delta t}{\varepsilon_r \Delta y} \left(H_{z,j+\frac{1}{2}}^{n+\frac{1}{2}} - H_{z,j-\frac{1}{2}}^{n+\frac{1}{2}} \right) \quad (3.43)$$

由於每一步更新皆直接利用前一時刻已知的場值，因此 FDTD 屬於顯式 (explicit) 時間積分方法。

同理，磁場 $H_z^{n+1/2}$ 也可以藉由前一個時間步長的磁場與更新時間步長之電場的空間差分計算得到。這種藉由時間更新迴圈 ($E^n \rightarrow H^{n+1/2} \rightarrow E^{n+1}$) 在時域中交替迭代的方法，就是 FDTD 方法的核心。

然而，在顯式時間迭代過程中，空間網格步長 ($\Delta x, \Delta y$) 與時間步長 (Δt) 並不能任意設定。為了確保數值解於時間迭代過程中保持穩定，避免產生非物理性的數值發散，時間步長必須根據空間離散的尺度來滿足 Courant-Friedrichs-Lewy (CFL) 穩定性條件。在一般的 d 維空間中，該數值穩定性條件要求：

$$\Delta t \leq \frac{1}{c \sqrt{\sum_{m=1}^d \frac{1}{\Delta x_m^2}}} \quad (3.44)$$

在 MEEP 採用的無因次單位制中，光速已設定為 $c = 1$ 。若假設模擬採用均勻的二維網格 ($\Delta x = \Delta y = \Delta$)，則公式(3.44)可化簡為：

$$\Delta t \leq \frac{\Delta}{\sqrt{2}} \approx 0.707\Delta \quad (3.45)$$

在實際應用中，MEEP 預設引用一個無因次的 Courant 因子 (Courant Factor) S ，定義為 $S = \Delta t / \Delta$ 。MEEP 預設將其保守地設定為 $S = 0.5$ (滿足小於 0.707 之要求)，以此來提供一般光學模擬足夠的數值穩定性。

3.1.3.3 Subpixel Smoothing

在傳統的有限差分時域法 (FDTD) 中，若直接將具有曲面或斜面的材料介面離散化到 YEE 晶格上，如圖 8 左側所示，真實的連續邊界會任意橫切過網格，若採用傳統非黑即白的二值化離散方式，實際的幾何邊界會被迫近似為鋸齒狀的輪廓，進而產生階梯效應 (Staircasing Effect)。這種幾何誤差會在材料介面的描述上降低其精確程度，使原本具備二階空間精確度的 FDTD 退化為一階收斂，並造成共振頻率、散射特性及傳輸效率等模擬結果的誤差。




圖 8: 傳統階梯化離散與次像素平滑之比較。左圖為連續幾何邊界橫切網格的原始狀態；右圖為 MEEP 於邊界網格配置等效介電常數，以改善材料介面的表示精度。[1]。

為了改善材料介面的離散化精確度，MEEP 採用了基於微擾理論 (Perturbation Theory) 的次像素平滑 (Subpixel Smoothing) 技術。如圖 8 右側與其放大圖所示，這個技術的核心概念是在邊界穿越的 Yee 網格內，以等效介電常數 $\tilde{\epsilon}$ 取代原本不連續的材料分布，這使得材料介面在次像素尺度上，獲得了平滑且具灰階過渡性質的描述。

根據微擾理論，為了消除材料介面離散化所引起的一階誤差，邊界網格內的有效介電常數必須表示為各向異性介電張量，其表示式為：

$$\epsilon_{\text{eff}} = \langle \epsilon \rangle \mathbf{P} + \langle \epsilon^{-1} \rangle^{-1} (\mathbf{I} - \mathbf{P}) \quad (3.46)$$

其中， $\mathbf{I}$ 為單位矩陣， $\mathbf{P} = \mathbf{nn}^T$ 為介面法向量的投影矩陣， $\langle \cdot \rangle$ 表示像素體積的平均值。

若以二維介面法向沿 x 方向為例，其等效介電常數可表示為：

$$\varepsilon_{xx} = \left(\frac{1}{\Delta x} \int_0^{\Delta x} \frac{1}{\varepsilon(x)} dx \right)^{-1} \quad (3.47)$$

$$\varepsilon_{yy} = \frac{1}{\Delta x} \int_0^{\Delta x} \varepsilon(x) dx \quad (3.48)$$

其中，垂直於介面的方向採用調和平均數 (Harmonic Mean)，平行於介面的方向則採用算術平均數 (Arithmetic Mean)。透過上述等效介電張量，MEEP 就可以有效地改善材料介面離散化所產生的誤差，使曲面或斜面介面的數值模擬重新恢復二階空間收斂性，因此能在不增加網格解析度的情況下，提高共振頻率、散射特性及傳輸效率等物理量的計算精確度。

3.1.3.4 Perfectly Matched Layer(PML)

在 MEEP 中我們要設定有限計算區，而在有限計算區內無法直接模擬無限開放空間，因此在 FDTD 模擬中必須在計算區域的邊界加入人工吸收層，目的是為了避免電磁波發散到邊界時，產生非物理性的反射，而影響到最終的模擬結果。MEEP 採用完美匹配層 (Perfectly Matched Layer, PML) 來作為吸收邊界條件。

MEEP 採用的單軸完美匹配層 (Uniaxial PML, UPML) 可以視為對座標進行複數延伸 (Complex Coordinate Stretching)，這樣可以使進入 PML 的電磁波逐漸衰減，以此來達到吸收電磁波的目的，並且不會在介面產生反射。

然而，PML 完美的無反射特性是建立在背景介質向外均勻延伸的假設之上。當非均勻結構直接截斷並延伸進入 PML 區域時，原先的解析延拓條件將遭到破壞。如圖 9 所示，這種物理結構在吸收層中的不連續性會引發明顯的反射偽影。對於這類問題，通常需要依賴額外的絕熱吸收器或增加 PML 的厚度來加以緩解。

PML failure for inhomogeneous media




圖 9: PML 在非均勻介質中的失效示意圖 [1]。

除了理論上的限制，為了降低 Yee 晶格離散化造成的反射，PML 區域內的人工導電率必須由介面開始逐漸增加，而不是突然地改變。MEEP 採用多項式導電率分布：

$$\sigma(x) = \sigma_{\max} \left(\frac{x}{L} \right)^d \quad (3.49)$$

其中， L 為 PML 厚度， d 為導電率分布階數 ($d = 1, 2, 3$)。

在實際的網格運算中，單純對上述連續的導電率函數進行點取樣仍不足以完全消除高頻的數值反射。如圖 10 左側所示，若未針對邊界網格進行特殊處理 (`is_integrated=False`)，網格邊界處仍會殘留可見的數值干涉波紋。為了進一步優化，MEEP 提供了將 PML 導電率在網格像素內進行精確積分的功能。如圖 10 右側所示，一旦啟動網格內精確積分 (`is_integrated=True`)，系統便能大幅平滑化離散帶來的數值突變，極其有效地抑制殘留的反射波。因此，在一般的光學結構模擬中，除了設定約大於一個工作波長的 PML 厚度外，配合精確的導電率積分設定，即可確保模擬區域內的物理場獲得最乾淨的無反射環境。




圖 10: PML 導電率函數之離散化處理對數值反射的影響。左圖 (`is_integrated=False`) 因採單純點取樣而產生明顯干涉波紋；右圖 (`is_integrated=True`) 透過像素內精確積分，大幅消除了殘留的數值反射 [1]。

3.1.3.5 Discrete Fourier Transform (DFT) and Mode Expansion

有限差分時域採用時域計算，因此可利用單一寬頻脈衝源 (Broadband Pulse Source) 同時激發多個頻率成分，再透過離散傅立葉轉換 (Discrete Fourier Transform, DFT) 取得各頻率下的頻域電磁場資訊。

在 MEEP 模擬過程中，使用者可以指定一個光場監測面 (Monitor Surface) 來計算各頻率的複數電磁場振幅。利用這些頻域電磁場，即可透過 Poynting 向量計算指定監測面的功率通量：

$$P(\omega) = \Re \iint_S [\mathbf{E}_\omega(\mathbf{r})^* \times \mathbf{H}_\omega(\mathbf{r})] \cdot d\mathbf{A} \quad (3.50)$$

其中， $\mathbf{E}_\omega(\mathbf{r})$ 與 $\mathbf{H}_\omega(\mathbf{r})$ 分別表示特定頻率 ω 下的複數電場與磁場空間振幅。

在傳統 FDTD 中，若要取得頻域資訊，通常需儲存監測面上所有時間步長的電磁場，再於模擬結束後進行傅立葉轉換。當模擬時間較長或頻率解析度較高時，就會造成記憶體需求增加。為了降低記憶體負擔，MEEP 採用離散時間傅立葉轉換 (Discrete-

Time Fourier Transform, DTFT) 的方法。在每一個時間步長 n 中，MEEP 會直接更新指定頻率 ω 的傅立葉累積值，其離散形式可表示為：

$$\mathbf{E}_\omega(\mathbf{r}) = \sum_n e^{i\omega n \Delta t} \mathbf{E}(\mathbf{r}, n \Delta t) \Delta t \quad (3.51)$$

$$\mathbf{H}_\omega(\mathbf{r}) = \sum_n e^{i\omega n \Delta t} \mathbf{H}(\mathbf{r}, n \Delta t) \Delta t \quad (3.52)$$

因此，只需要在模擬過程中累積指定頻率的傅立葉係數，模擬結束後即可直接得到各頻率下的複數電磁場，進而計算功率通量。

對於多模態波導，由於總通量無法區分各個模態所攜帶的能量分布，因此 MEEP 提供模態展開 (Mode Expansion) 的功能。這個方法主要是利用 MPB 求解波導截面的特徵模態，再將 DFT 所得到的頻域電磁場投影到各個特徵模態上，以此來分離不同模態所攜帶的功率。

因此，透過 DFT 與 Mode Expansion 的結合，MEEP 能同時提供元件的頻譜響應、功率通量以及計算各模態的傳輸效率，這使它成為模擬分析矽光子、光學元件的強大工具。

3.2 Structured Encoding and Dimensionality Reduction

本研究採用退火最佳化 (Annealing Optimization) 作為全域最佳化方法，以搜尋二維光學結構的最佳設計。由於退火最佳化需將設計問題表示為二元二次最佳化 (Quadratic Unconstrained Binary Optimization, QUBO) 形式，因此設計結構必須以二元設計變數 (binary design variables) 進行表示。若採用傳統的像素化 (pixel-based) 設計方式，通常需要透過增加設計區域的解析度來提升結構的設計自由度。然而，解析度的提升意味著設計變數將會大幅增加，使得最佳化問題的維度與 QUBO 問題的規模大幅成長，進而提高計算成本。而對於量子退火 (Quantum Annealing) 而言，龐大的問題規模更會導致量子位元 (qubits) 資源需求大增，受限於當前量子硬體的物理限制。

為了克服高維度結構所帶來的計算瓶頸，本章節將會探討三種不同的編碼 (Encoding) 方法，包括高斯上採樣 (Gaussian Upsampling)、二維傅立葉積分 (2D Fourier Integral) 以及 β -Variational AutoEncoder(β -VAE)。其中，高斯上採樣利用高斯平滑 (Gaussian Smoothing) 改善離散二元結構的空間表示，以產生更平滑的結構邊界；二維傅立葉積分則透過二元變數 $\alpha_{m,n}$ 來控制各個傅立葉基底的啟用與否，以傅立葉基底的組合形式來建立二維光學結構；最後， β -VAE 透過訓練生成式模型來學習將高維度的結構資料映射成低維度的潛在空間 (latent space)，進一步降低最佳化問題的維度並且提升搜尋效率。以下各個小節將會介紹上述三種編碼方法的理論基礎。

3.2.1 Spatial Smoothing via Gaussian Upsampling

傳統的像素化設計方法通常是將光學結構離散化為一個二元矩陣，其中每個元素分別代表著不同材料。然而這種離散的表示法存在兩個問題：第一個，隨著結構解析度的提升，設計變數的數量將會呈現二次方增加，導致退火演算法面臨嚴重的維度災難；第二個，二元獨立變數容易在邊界產生鋸齒狀，這種結構在實際半導體製程是無法實現

的。

為了解決上述問題，在本篇研究中引入了高斯上採樣 (Gaussian Upsampling) 的編碼方式。此方法的核心概念為「低維度離散變數，高解析度連續結構」。我們首先在一個低解析度的二維實數空間中定義一組較少的二元設計變數矩陣 $X_{\text{low}} \in \{0, 1\}^{N_{\text{low}} \times N_{\text{low}}}$ ，如圖 11 所示，其中矩陣元素中的 1 表示在該位置放置某個特定材料 (例如高折射率材料)，而 0 表示背景預設材料 (例如矽的基底)，而我們使用的退火演算法只需要在這種低維度的搜尋空間中尋找最佳解。




圖 11: 二元變數矩陣示意圖。

上採樣的第一步，是針對低維度二元方塊中數值為 1 的部分進行上採樣映射。為了消除放大後的鋸齒邊界與尖角，我們在像素空間中定義一個二維對稱的高斯捲積核 (Gaussian Convolution Kernel) $K(i, j)$ ，其權重分布符合高斯分布，並且進行歸一化確保

總和為 1，如公式 3.53 所示：

$$K(i, j) = A \cdot \exp\left(-\frac{i^2 + j^2}{2\sigma_{\text{pix}}^2}\right) \quad (3.53)$$

其中， σ_{pix} 為像素單位下的高斯標準差， A 為歸一化因子，使得在卷積核視窗大小 W 內的權重總和滿足 $\sum_{i,j} K(i, j) = 1$ 。

接著進行空間濾波，原本陡峭的 (0/1) 方塊邊界會被模糊化，形成介於 0 與 1 之間的「灰階過渡帶」，物理上也等同於對結構進行了空間平滑化，因此我們會得到一張由二元設計變數矩陣卷積過後的高解析度灰階圖，如圖 12 所示。




圖 12: 高斯上採樣後的灰階示意圖。

但是灰階圖無法進行光學模擬，因此我們為了重新將連續灰階值轉換回接近二元的結構邊界，我們採用了雙曲正切投影 (Tanh Projection)，如公式(3.54)所示，對濾波後的

連續密度場 $\tilde{\rho}$ 進行非線性投影:

$$\bar{\rho} = \frac{\tanh(\beta \cdot \eta) + \tanh(\beta \cdot (\tilde{\rho} - \eta))}{\tanh(\beta \cdot \eta) + \tanh(\beta \cdot (1 - \eta))} \quad (3.54)$$

其中， β 為控制投影的陡峭程度， η 為投影閾值。

當 β 足夠大時，該投影函數極度接近階梯函數（Heaviside step function），最終的物理密度分佈 $\bar{\rho}$ 可簡化為:

$$\bar{\rho} \approx \begin{cases} 1, & \text{if } \tilde{\rho} > 0.5 \\ 0, & \text{if } \tilde{\rho} \leq 0.5 \end{cases} \quad (3.55)$$

這表示只有在高斯濾波後的局部密度大於 0.5 的區域，才會在投影後被判定為 1(例如高折射材料)，否則會被判定為 0(預設基底材料)，如圖 13 所示。




圖 13: 高斯上採樣後的二元平滑化示意圖。

在這種結合高斯濾波與雙曲正切投影架構下，最後產生幾何結構的最小特徵尺寸

(Minimum Feature Size, MFS) $b_{\min}$ 將會受到高斯標準差 σ 的限制。滿足製程可行性的臨界條件為：

$$\text{erf}\left(\frac{b}{2\sqrt{2}\sigma}\right) \geq 0.5 \implies \frac{b}{2\sqrt{2}\sigma} \geq \text{erf}^{-1}(0.5) \approx 0.47693 \quad (3.56)$$

透過公式(3.56)可推導出物理空間容許存在的最小特徵尺寸 $b_{\min}$ 關係式：

$$b_{\min} \approx 1.35 \cdot \sigma_{\text{pix}} \cdot d \quad (3.57)$$

由公式(3.57)可知，當設計區域的細網格尺寸 d 固定時，此方法可以透過定量調整 σ_{pix} 來控制結構的最小特徵尺寸，使其嚴格符合半導體製程的最小線寬限制 ($b_{\min} \geq b_{\text{fab}}$)。同時，為了避免高斯核在邊緣因為強行截斷而導致幾何結構變形，卷積核的視窗大小 W 必須滿足 $W \geq 6\sigma_{\text{pix}} + 1$ 且取奇數，以保證高斯分布的完整性與結構的幾何對稱性。

為了具體說明如何應用公式(3.57)來控制設計區域的最小特徵尺寸，我將會在第 4.2.1 節中詳細舉例並說明。

3.2.2 2D Fourier-Based Representation via Basis Selection

為了降低二維光學結構反向設計問題的自由度，此方法不直接以設計區域中每一個像素的材料選擇作為最佳化變數，而是採用頻譜編碼 (Spectral Encoding) 的方法，將結構的設計變數表示為有限個二維正弦基底函數所構成的低維頻域空間中。透過限制可使用的空間頻率成分，使生成出的結構具有較平滑的幾何特徵，並且可以有效減少設計變數的維度，使退火演算法能夠更容易搜尋到最佳解。

假設設計區域的物理尺寸為 $L_x \times L_y$ ，離散後的空間座標分別記為 x 與 y 。結構的連

續場可以透過有限個二維正弦基底函數透過設計變數疊加來表示：

$$F(x, y) = \sum_{m=1}^M \sum_{n=1}^N \alpha_{m,n} \cdot \sin(m\pi x) \cdot \sin(n\pi y) \quad (3.58)$$

其中， m 與 n 分別表示 x 與 y 方向的頻譜模態階數， M 與 N 表示能夠選擇的最大頻譜模態數，而 $\alpha_{m,n}$ 分別對應第 (m, n) 個頻譜基底的係數，也就是我們的設計變數，其定義為二元變數：

$$\alpha_{m,n} \in \{0, 1\}. \quad (3.59)$$

當 $\alpha_{m,n}$ 中的某階元素數值為 1 時，表示此階的頻率成分被納入頻率疊加中；相反地，當 $\alpha_{m,n}$ 中的某階元素值為 0 時，表示此階的頻率成分不參與疊加。因此，所有頻譜係數可展開為二元向量，如圖 14 所示。






圖 14: 二維頻譜係數 $\alpha_{m,n}$ 展開為二元設計向量之示意圖

相較於直接為設計區域中的每一個網格指定材料，這種方法只需要調整有限數量的頻譜係數就可以設計出完整的二維結構。因此，可以大幅減少需要優化的變數數量。



(a) 三維連續數值場 $F(x, y)$ 之示意圖



(b) 二維連續數值場 $F(x, y)$ 之示意圖

圖 15: 連續數值場 $F(x, y)$ 之示意圖

由於公式(3.58)所疊加出的連續數值場 $F(x, y)$ ，如圖 15 所示，還不能直接當作二元材料結構使用，因此，如公式(3.60)所示，我引用了 Heaviside step function，並且定義一個閥值常數 C_{th} ，將立體的連續場轉換為平面的二元結構函數 $\rho(x, y)$:

$$\rho(x, y) = H[F(x, y) - C_{th}] \quad (3.60)$$

其中， $H[\cdot]$ 為 Heaviside step function，在此研究中設定 $C_{th} = 0$ ，當頻譜疊加場在某個位置的數值大於零時，這個位置就會被視為 $\rho = 1$ ；相反地，小於零時則會被視為 $\rho = 0$ ，因此二元矩陣 $\rho(x, y)$ 所構成的二元矩陣就成了設計區域中的材料分布，如圖 16 所示。

在本研究中的電磁模擬，二元結構函數 $\rho(x, y)$ 被映射為兩種材料的材料分布，其中 $\rho(x, y) = 1$ 對應為矽 (Si)， $\rho(x, y) = 0$ 則對應為二氧化矽 (SiO_2)。




圖 16: 由二元設計矩陣 $\rho(x, y)$ 所構成的二元矩陣即構成設計區域中的材料分布

由於只有保留有限數量的低階正弦模態，這種頻譜編碼的方式會自動減少過高的空間頻率的成分。也就是說，生成結構的最小特徵尺寸會受到最大模態階數 M 與 N 的限制。當今天退火演算法選擇了較低的模態數時，結構通常會較平滑且尺度較大；相反地，當演算法選擇較高的模態數時，結構的形狀會更複雜並且有更多細小結構。因此，模態數 M, N 的選擇就成了需要在設計自由度、結構可製造性與最佳化效率之間取得平衡的設計參數。

3.2.3 β -Variational Autoencoder for Latent Space Representation

本研究中另外參考了 DeepMind 團隊在 2017 年發布的研究 [25] 以及普渡大學在 2021 年發布的研究 [36]，採用了第三種的編碼策略：引入 β 變分自編碼器 (beta-Variational Autoencoder β -VAE) 作為低維潛在空間 (Latent Space) 表示的模型，此方法可將原始高維結構資料映射至低維潛在向量，並透過因子分解機與退火演算法去尋找怎麼樣的低維潛在空間能夠透過解碼器有效地描述出我們想要的光學結構。本節將說明 β -VAE 的基本理論；其實際模型架構、訓練流程與最佳化方法，則於第四章中進一步介紹。

變分自編碼器 (Variational Autoencoder, VAE) 為一種生成式模型，其目的在於學習

資料之潛在機率分布，並建立由低維潛在空間重建原始資料之映射關係。在本研究中， β -VAE 將高維結構資料 $\mathbf{x}$ 經由編碼器壓縮至低維潛在向量 $\mathbf{z}$ ，再由解碼器重建為對應結構 $\hat{\mathbf{x}}$ 。

傳統自編碼器直接學習確定性映射，也就是輸出在相同輸入條件下是唯一且固定的；而 VAE 則將潛在變數視為機率分布，表示潛在空間會具有可採樣性與一定程度的不確定性。編碼器不直接輸出潛在向量，而是輸出近似後驗分布 $q_\phi(\mathbf{z}|\mathbf{x})$ 的參數 (平均值 μ 與標準差 σ):

$$q_\phi(\mathbf{z}|\mathbf{x}) = \mathcal{N}(\mu(\mathbf{x}), \text{diag}(\sigma^2(\mathbf{x}))) \quad (3.61)$$

接著由該分布取樣得到潛在向量 $\mathbf{z}$ ，並輸入解碼器以生成重建結果 $\hat{\mathbf{x}}$ 。為使模型可透過反向傳播進行訓練，引入重參數化技巧 (reparameterization trick):

$$\mathbf{z} = \mu + \sigma \odot \epsilon, \quad \epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I}) \quad (3.62)$$

其中 $\odot$ 表示逐元素相乘 (element-wise product)。變分自編碼器的整體架構與資料流向示意圖如圖 17 所示。




圖 17: 變分自編碼器的整體架構與資料流向示意圖

由於本研究之設計變數為二元離散形式，若直接進行離散取樣將造成不可微分問

題，因此在解碼端採用 Gumbel-Softmax 方法，可以建立離散設計變數的可微分近似表示。

如果要從具有 K 個類別的機率分布中進行採樣，Gumbel-Max 方法會在各類別的對數機率 $\log \alpha_k$ 中加入獨立同分布的 Gumbel 雜訊 G_k ，並將離散採樣表示為：

$$y_k = \text{one_hot} \left(\arg \max_k (\log \alpha_k + G_k) \right) \quad (3.63)$$

其中 $G_k = -\log(-\log U_k)$ ，且 U_k 滿足均勻分布 $\text{Uniform}(0, 1)$ 。

然而，公式 (3.63) 中的 $\arg \max$ 為離散操作，在大部分區域梯度皆為零，表示它本質上還是不可微。Gumbel-Softmax 進一步使用連續可微的 Softmax 函數來接近 $\arg \max$ 的離散輸出。其連續近似的輸出向量 $\mathbf{y} = [y_1, y_2, \dots, y_K]^T$ 中，第 k 個元件的計算公式可以表示為：

$$y_k = \frac{\exp \left(\frac{\log \alpha_k + G_k}{\tau} \right)}{\sum_{j=1}^K \exp \left(\frac{\log \alpha_j + G_j}{\tau} \right)} \quad (3.64)$$

其中 τ 表示為溫度參數 (Temperature Parameter)。如圖 18 所示，溫度參數 τ 對分布的控制機制為：

- 當 τ 較大時：輸出機率分布較為平滑，各類別之間的差異較小。在二元情況下，輸出值通常較接近 0.5。
- 當 τ 逐漸降低時：輸出分布會逐漸集中於其中一個類別，並趨近於 one-hot 向量。在二元情況下，輸出將接近 0 或 1。




圖 18: 不同的溫度參數 τ 對 Gumbel-Softmax 分布之影響示意圖

β -VAE 則是保留著傳統 VAE 的基礎，透過在目標函數下界 (Evidence Lower Bound, ELBO) 中引入一個用來調節的超參數 β 。其核心優化目標函數可表示為：

$$\mathcal{L}_{\beta\text{-VAE}}(\theta, \phi; \mathbf{x}) = \mathbb{E}_{q_{\phi}(\mathbf{z}|\mathbf{x})}[\log p_{\theta}(\mathbf{x}|\mathbf{z})] - \beta D_{\text{KL}}(q_{\phi}(\mathbf{z}|\mathbf{x}) \parallel p(\mathbf{z})) \quad (3.65)$$

此目標函數可以拆解成兩個部分：

- **重建損失 (Reconstruction Term):** 在公式(3.65)中的第一項 $\mathbb{E}_{q_{\phi}(\mathbf{z}|\mathbf{x})}[\log p_{\theta}(\mathbf{x}|\mathbf{z})]$ ，主要功能是用來衡量重建結構 $\hat{\mathbf{x}}$ 與原始結構 $\mathbf{x}$ 之間的差異程度。此項越大，代表解碼器重建的結果越接近原始輸入資料。
- **KL 散度 (Kullback-Leibler Divergence, KL Divergence):** 在公式(3.65)中的第二項 $D_{\text{KL}}(\cdot)$ ，主要功能是用來衡量後驗分布 $q_{\phi}(\mathbf{z}|\mathbf{x})$ 與先驗分布 $p(\mathbf{z})$ 之間的差異。

當 $\beta > 1$ 時，KL 散度項的權重提高，使近似後驗分布受到更強的先驗約束。這個約束可以降低不同潛在維度之間的相關性，使得潛在空間較為傾向於解耦特性。

在解耦後的潛在空間中，潛在向量 $\mathbf{z}$ 的每一個獨立維度 (獨立變數) 對應到了光學結構中的幾何特徵，例如材料分布、幾何結構等等，但並不是絕對，因此本研究在後續透過因子分解機建立潛在向量與光學性能之間的近似關係，並結合退火演算法於潛在空間中搜尋，以設計出符合我們預期的光學結構。

3.3 Factorization Machines and Annealing Optimization

在這個章節中，我會說明如何利用因子分解機 (Factorization Machine, FM) 建立多元非線性映射之代理模型 (Surrogate Model)，並推導如何將目標函數精確地映射為二次無約束離散優化問題 (Quadratic Unconstrained Binary Optimization, QUBO) 的形式，最後，我們會探討如何透過模擬退火 (Simulated Annealing, SA) 或量子退火 (Quantum Annealing, QA) 來求解 QUBO 問題，進行最佳組合搜尋的基礎理論。

3.3.1 Factorization Machine-based Surrogate Model Theory

此小節主要參考 Rendle 在 2010 年發表的 Factorization Machine[16]，在多元非線性函數中，自變數與因變數之間往往存在著複雜且非線性的映射關係，通常需要引入高泛化能力的代理模型來建立近似關係。傳統多項式回歸模型 (如 Support Vector Machine, SVM) 在處理高維度的特徵組合時，其二階交互項的參數皆為完全獨立。若要要求在此架構下的特徵組合 x_i 與 x_j 同時有足夠的非零觀測值，在稀疏的資料集下會無法估算參數 (即 $w_{i,j} = 0$)，進而導致模型的泛化能力大幅下降。

因此，Steffen Rendle 提出了具有二階項的因子分解機 (Second-order Factorization Machine)，其數學表示式定義如下：

$$\hat{y}(\mathbf{x}) = w_0 + \sum_{i=1}^n w_i x_i + \sum_{i=1}^n \sum_{j=i+1}^n \langle \mathbf{v}_i, \mathbf{v}_j \rangle x_i x_j \quad (3.66)$$

其中 $\mathbf{x} = [x_1, x_2, \dots, x_n]^T \in \mathbb{R}^n$ 為一組輸入特徵向量， $\hat{y}(\mathbf{x})$ 為輸出的預測值， $w_0 \in \mathbb{R}$ 為全域偏差 (Global Bias)， $w_i \in \mathbb{R}$ 為一階線性權重向量 $\mathbf{w}$ 的分量，功能為計算單一變數的強度。

FM 的核心在於將二階交互作用之權重定義為兩個低維向量的點積，也就是 $\hat{w}_{i,j} = \langle \mathbf{v}_i, \mathbf{v}_j \rangle$ 。參數矩陣 $\mathbf{V} \in \mathbb{R}^{n \times k}$ 包含所有特徵維度之隱向量 (Latent Vector)， $k \in \mathbb{N}_0^+$ 表示

潛在向量的維度 ($k \ll n$)，其點積項展開如下：

$$\langle \mathbf{v}_i, \mathbf{v}_j \rangle = \sum_{f=1}^k v_{i,f} \cdot v_{j,f} \quad (3.67)$$

因此， k 可以控制 FM 表達二階交互作用的能力與模型複雜度：

- **k 越大：**參數較少，訓練時間也較短，比較不容易過擬合 (Overfitting)，但也可能無法充分地描述複雜的特徵。
- **k 越小：**可以表達更複雜的交互作用關係，但需要更多訓練資料與計算成本，同時也較容易過擬合。

雖然公式 (3.66) 中的二階交互作用項需考慮所有特徵對 $((i,j))$ ，若直接計算其內積，時間複雜度將為 $\mathcal{O}(kn^2)$ 。然而，Rendle 在文獻 [16] 中所提出之 FM 模型可透過代數重組，將二階交互作用項推導為只需線性時間即可完成的形式。其推導如下：

$$\begin{aligned} \sum_{i=1}^n \sum_{j=i+1}^n \langle \mathbf{v}_i, \mathbf{v}_j \rangle x_i x_j &= \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \langle \mathbf{v}_i, \mathbf{v}_j \rangle x_i x_j - \frac{1}{2} \sum_{i=1}^n \langle \mathbf{v}_i, \mathbf{v}_i \rangle x_i^2 \\ &= \frac{1}{2} \left(\sum_{i=1}^n \sum_{j=1}^n \sum_{f=1}^k v_{i,f} v_{j,f} x_i x_j - \sum_{i=1}^n \sum_{f=1}^k v_{i,f}^2 x_i^2 \right) \\ &= \frac{1}{2} \sum_{f=1}^k \left(\left(\sum_{i=1}^n v_{i,f} x_i \right) \left(\sum_{j=1}^n v_{j,f} x_j \right) - \sum_{i=1}^n v_{i,f}^2 x_i^2 \right) \\ &= \frac{1}{2} \sum_{f=1}^k \left(\left(\sum_{i=1}^n v_{i,f} x_i \right)^2 - \sum_{i=1}^n v_{i,f}^2 x_i^2 \right) \end{aligned} \quad (3.68)$$

經由上述代數重組後，二階交互作用項不需要逐一計算所有特徵對。對於每一個因子維度 f ，只需要計算 $\sum_{i=1}^n v_{i,f} x_i$ 與 $\sum_{i=1}^n v_{i,f}^2 x_i^2$ 兩項，其計算時間皆為 $\mathcal{O}(n)$ 。因此，當潛在向量維度為 k 時，二階交互作用項的總時間複雜度可由 $\mathcal{O}(kn^2)$ 降為 $\mathcal{O}(kn)$ 。

在此研究中所使用的 Factorization Machines 模型皆透過 Pytorch 重新實作，並且依照公式(3.68)推導結果計算二階交互作用項，採用線性時間的形式，使其時間複雜度維持

為 $\mathcal{O}(kn)$ ，進而降低模型訓練時的運算成本並提升訓練效率。

3.3.2 Combinatorial Optimization and QUBO Transformation

當設計變數限制為二元離散狀態 (即 $x_i \in \{0, 1\}$) 時，尋找目標函數全域極值的問題可視為組合最佳化 (Combinatorial Optimization) 問題。以二維光學結構為例，假設每個設計區域只能選擇兩種材料，並且將 $x_i = 0$ 與 $x_i = 1$ 分別視為該位置選擇不同材料，這時候最佳化的目的就不是連續調整各區域的材料參數，而是在所有可能的材料排列組合中，尋找能夠使元件效能最佳的結構組合。

在此研究中，為了使用量子退火或模擬退火演算法等方法進行求解，我們必須先將目標函數轉換為二次無約束二元最佳化 (Quadratic Unconstrained Binary Optimization, QUBO) 形式

QUBO 問題的目標函數可表示為：

$$E(\mathbf{x}) = \sum_{i=1}^N q_i x_i + \sum_{i=1}^N \sum_{j=i+1}^N Q_{ij} x_i x_j, \quad (3.69)$$

其中， $\mathbf{x} = [x_1, x_2, \dots, x_N]^T$ 為二元決策變數向量，而每個變數 x_i 只能取 0 或 1； q_i 為單一變數的線性偏差 (Linear Biases)， Q_{ij} 為描述變數 x_i 與 x_j 之間的二次耦合關係 (Quadratic Couplings)。

透過公式 (3.66) 與 (3.69) 可以發現，當 FM 模型的輸入限制為二元變數時，FM 模型的目標函數同樣由線性項與二次交互作用項組成。因此，FM 模型中的一階項 $w_i x_i$ 可直接對應到 QUBO 的線性項 $q_i x_i$ ；二階交互作用項 $\langle \mathbf{v}_i, \mathbf{v}_j \rangle x_i x_j$ 則可對應到 QUBO 的耦合項 $Q_{ij} x_i x_j$ 。FM 中的全域偏差只會改變目標函數的整體數值，並不會影響最佳化結果，因此可以在 QUBO 求解時省略。

依據上述的對應關係，FM 模型完成訓練後，可以直接將其一階權重與二階交互作用係數轉換為 QUBO 形式的線性係數與耦合矩陣。並且由於 FM 的二階係數是由隱向

量的內積計算而得，因此並非每一組變數間的耦合強度都可以獨立設定，而是受到隱向量維度 k 的限制。也就是，FM 模型所建立的 QUBO 矩陣具有低秩特性。相較於一般連續型非線性模型，此方法不需要先將離散變數放寬為連續區間再進行近似最佳化，也不需要加入懲罰項來限制解的空間，因此可以減少轉換與求解的前置處理步驟。

3.3.3 Quantum and Simulated Annealing Mechanisms

此小節中，我將分別探討模擬退火 (Simulated Annealing, SA) 與量子退火 (Quantum Annealing, QA) 兩種退火機制。在本研究中，這兩種方法都是以 D-Wave 公司開發的架構所對應之數學模型為基礎，用來求解轉換後的 QUBO 矩陣。在研究中利用這兩種退火機制的目的，主要在於複雜且具有大量離散解的搜尋空間中，避免演算法停留在局部最佳解 (Local Minima)，並且進一步尋找能量較低、接近全域最佳解 (Global Minima)。

3.3.3.1 Simulated Annealing Mechanism

本研究中所採用的模擬退火機制是基於 D-Wave 開源框架 dimod 中的模擬退火採樣器 (SimulatedAnnealingSampler)。此方法屬於經典隨機最佳化演算法，透過模擬熱力學退火過程來近似伊辛模型 (Ising Model) 的最低能量解。在此架構下，系統透過熱漲落 (Thermal Fluctuations)，允許系統在一定機率下接受能量較高的較差解，以提升跳出局部最小值之機率。在 1983 年 Kirkpatrick 等人發表的 Optimization by simulated annealing[14] 中提到，這種狀態轉移的接受機率遵循梅特羅波利斯準則 (Metropolis Criterion):

$$P(\text{accept}) = \min \left(1, \exp \left(-\frac{\Delta E}{T} \right) \right) \quad (3.70)$$

其中， $\Delta E = E(\text{snew}) - E(\text{sold})$ 表示系統由當前狀態轉移至候選狀態的能量變化， $T \in \mathbb{R}^+$ 為虛擬溫度。在退火過程中，系統會依照其預設的降溫策略 (Beta Schedule) 隨著 sweep 增加而降低溫度，使接受較差解的機率逐漸降低，系統行為因此由初始階段的全域隨機搜尋逐漸轉變為局部收斂，最後會穩定於低能量解。

3.3.3.2 Quantum Annealing Mechanism

本小節內容主要參考 D-Wave 官方文件 [37] 及其量子退火相關技術說明。

相較於模擬退火 (Simulated Annealing, SA)，量子退火 (Quantum Annealing, QA) 則是利用量子疊加 (Quantum Superposition) 與量子穿隧效應 (Quantum Tunneling) 進行最佳組合搜尋。對於透過 Factorization Machine 模型轉換成 QUBO 問題，除了可以使用模擬退火的方法求解，也可以改寫成伊辛模型 (Ising Model)，並利用 D-Wave 量子電腦 (QPU) 進行量子退火求解。

對於二元變數 $x_i \in \{0, 1\}$ ，可以透過：

$$s_i = 2x_i - 1, \quad s_i \in \{-1, +1\} \quad (3.71)$$

將其轉換為伊辛自旋變數。轉換後，伊辛模型的能量函數可以表示成：

$$E_{\text{Ising}}(\mathbf{s}) = \sum_{i=1}^N h_i s_i + \sum_{i=1}^N \sum_{j=i+1}^N J_{ij} s_i s_j \quad (3.72)$$

其中， h_i 為第 i 個自旋的偏差項， J_{ij} 為第 i 與第 j 個自旋之間的耦合係數。伊辛模型的能量函數與 QUBO 目標函數(3.69)只有相差一個常數項，因此兩者具有相同的最佳解，這也是為什麼我們恰好可以利用量子退火機制求解 QUBO 問題。

對於 QUBO 係數的 q_i 與 Q_{ij} ，分別對應的伊辛係數可以寫成 J_{ij} 與 h_i ：

$$J_{ij} = \frac{Q_{ij}}{4}, \quad i < j \quad (3.73)$$

$$h_i = \frac{q_i}{2} + \frac{1}{4} \sum_{j \neq i} Q_{ij} \quad (3.74)$$

在 D-Wave 系統中，伊辛模型可以表示為問題哈密頓量 (Problem Hamiltonian)(3.75)：

$$H_P = \sum_i h_i \sigma_i^z + \sum_{i < j} J_{ij} \sigma_i^z \sigma_j^z, \quad (3.75)$$

其中， σ_i^z 為第 i 個量子位元的 Pauli-Z 算符，其測量結果會對應至自旋狀態 $s_i \in \{-1, +1\}$ 。

量子退火過程主要是由與時間相關的總哈密頓量(3.76)來控制：

$$H(t) = A(t)H_D + B(t)H_P, \quad (3.76)$$

其中， $H_D = -\sum_i \sigma_i^x$ 為驅動哈密頓量 (Driver Hamiltonian)，主要由橫向磁場構成。在退火初期， $A(0) \gg B(0)$ ，這時候系統主要是由驅動哈密頓量來控制，使量子位元呈現出具有不同自旋的疊加狀態。在退火過程中， $A(t)$ 會逐漸減小，而 $B(t)$ 也會逐漸增加，使問題哈密頓量的對系統的影響會逐漸變大。當退火到最後 ($t = t_f$) 時，系統的結果主要會由問題哈密頓量決定，經過測量後就會得到一組對應於 QUBO 問題的二元解。

因此，在理想的絕熱演化條件下，如果哈密頓量的變化速度足夠緩慢，系統就可以維持接近瞬時基態，並且取得較低能量的解。但實際上 D-Wave QPU 的結果還是多少會受到退火時間、熱擾動、量子位元雜訊及問題嵌入 (Embedding) 方式的影響。

在本研究中雖然大部分使用模擬退火，但是對於轉換後的 QUBO 問題，兩者皆可作為求解方法。

第四章、Method and Results

4.1 Factorization Machine with Annealing Optimization Framework

本研究採用的最佳化方法為 Factorization Machine with Annealing Optimization。這個方法主要是參考 Kitai 等人於 2020 年提出之 *Designing Metamaterials with Quantum Annealing and Factorization Machines*[17]。此研究建立了一個結合因子分解機 (Factorization Machine) 與量子退火 (Quantum Annealing) 的 FMQA 架構，透過因子分解機建立目標函數的代理模型，並將其轉換為二元二次最佳化問題，再利用量子退火搜尋候選設計。

然而，本研究並沒有直接使用量子退火作為 QUBO 求解器，而是採用模擬退火 (Simulated Annealing, SA) 進行候選結構搜尋。因此，本研究保留了 FMQA 架構中「FM 代理模型、QUBO 轉換與退火搜尋」的核心流程，並以 SA 取代原始架構中的 QA，將其應用於反向設計。

在本章節中我會說明 Factorization Machine with Annealing Optimization 的架構以及實際的完整執行流程。首先我會介紹初始結構資料集的建立方式，接著說明 FM 代理模型之訓練，以及其模型參數轉換為 QUBO 問題的流程。然後，我會說明本研究如何使用 SA 求解 QUBO 問題，以產生具潛力之候選結構。最後，我將介紹候選結構經過解碼與 FDTD 模擬評估後，如何回饋至訓練資料集，並透過重複訓練與搜尋一步一步完成結構最佳化。另外，不同結構編碼策略的設計與實作方式也不盡相同，因此我會於後續章節中進一步說明。

Factorization Machine with Annealing Optimization 整體流程如圖 19所示，主要流程可概分為下列步驟：

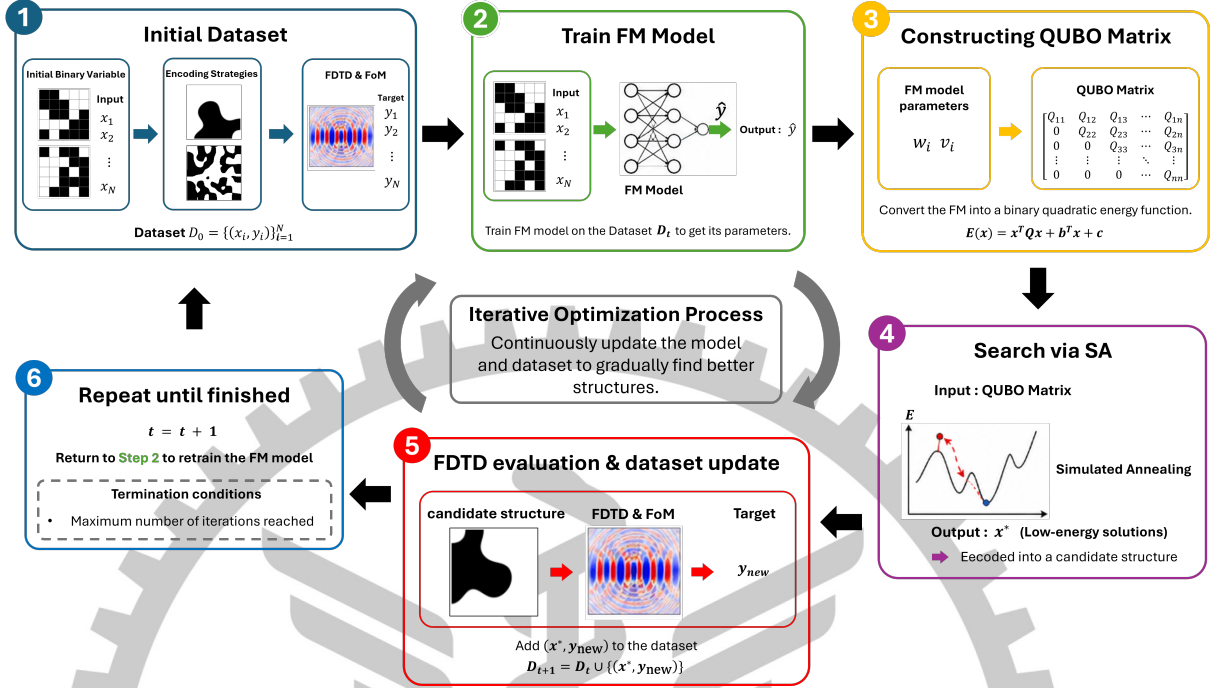


圖 19: Factorization Machine with Annealing Optimization 整體流程圖。

一、建立初始訓練資料集 (Initial Dataset Generation)

一開始會先隨機產生一組初始隨機二元變數 (Initial Random Binary Variables) x_i ，這些二元變數是沒有經過任何結構約束或模型訓練的。接著我們會透過特定的編碼策略 (Encoding Strategies) 來對初始二元變數進行編碼 (Encoding)，這時候我們就會得到一組平滑化後的二維結構圖。接著，針對這些隨機二元變數編碼後的二維結構圖，利用有限時域差分法 (Finite-Difference Time-Domain, FDTD) 進行電磁模擬，取得其光學效率，例如特定波長下的傳輸率。再根據模擬結果計算品質因子 (Figure of Merit, FoM)，這邊我們可以記為 y_i 。最終可建立包含 N 筆資料的初始訓練資料集 D_0 ：

$$D_0 = (x_i, y_i)_{i=1}^N. \quad (4.1)$$

此資料集會作為後續模型訓練的基礎。

二、訓練因子分解機代理模型 (Training the FM Surrogate Model)

為了降低直接透過 FDTD 模擬龐大設計空間所需的計算成本，在研究中採用因子分解機 (Factorization Machine, FM) 作為代理模型。將第一步所建立的初始訓練資料集 D_0 中的隨機設計變數 x_i 與對應 FoM y_i 輸入因子分解機進行監督式訓練，使模型學習設計變數中每個矩陣元素與光學性能之間的關係。

訓練完成後，因子分解機可以得到線性權重 w_i 與二階交互作用參數 v_i 。其中，二階項 v_i 用來描述不同結構變數間的交互作用，並作為下一步用來轉換為 QUBO 問題的依據。

三、建構無約束二元二次最佳化問題 (Constructing the QUBO Problem)

根據訓練完成的因子分解機模型參數，可以將預測函數 $\hat{y}$ 轉換為無約束二元二次最佳化 (Quadratic Unconstrained Binary Optimization, QUBO) 形式。經過轉換後，目標能量函數可以表示為：

$$E(x) = x^T Q x + b^T x + c, \quad (4.2)$$

其中， Q 為二次交互作用矩陣， b 為線性項， c 為常數項。如果設計目標是最大化元件的傳輸率或 FoM，我們可以在程式中調整目標函數的正負號，讓最大化問題可以隨著最小化能量函數 $E(x)$ 降低而降低。

四、以模擬退火演算法搜尋候選結構 (Candidate Structure Search via SA)

將 QUBO 問題輸入模擬退火 (Simulated Annealing) 演算法進行求解。SA 透過隨機擾動與逐步降溫等機制來進行採樣，以探索出它認為最有潛力的二元設計變數，並且可降低搜尋過程陷入局部最佳解的機率。求解完成後，就可以得到預測出的一組二元設計變數 x^* 。

接著，預測出的二元設計變數會依照不同的編碼策略再轉換為其對應的二維光學結構圖，來作為下一步 FDTD 模擬的候選結構。

五、FDTD 評估與資料集更新 (FDTD Evaluation and Dataset Update)

將 SA 搜尋得到的候選結構輸入 FDTD 模擬，以用來計算其光學性能及目標函數值 y_{new} 。完成模擬後，將新結構 x^* 及其對應 FoM y_{new} 加入原本的資料集 D_t ，得到更新後的訓練資料集 D_{t+1} ：

$$D_{t+1} = D_t \cup (x^*, y_{\text{new}}). \quad (4.3)$$

透過持續迭代並加入高光學性能的結構資料集，可以提升因子分解機模型的預測能力。

六、重複迭代至終止條件 (Iterative Optimization Process)

上述的步驟可以構成一個閉環式的最佳化流程。在每次資料集 D_t 更新後，重新訓練因子分解機模型，並重複執行 QUBO 建構、SA 搜尋與 FDTD 模擬驗證。隨著迭代的進行，資料集 D_t 會慢慢增加良好 FoM 的資料，使因子分解機模型能夠更有效的在設計空間中引導搜尋方向。當達到程式預設的最大迭代次數 (例如 100 次) 時，將會停止整個最佳化的流程。

4.2 Encoding Strategies for Factorization Machine with Annealing Optimization

在因子分解機結合模擬退火的架構中，結構表示方式會直接影響因子分解機作為代理模型的訓練效率、QUBO 問題的維度，以及模擬退火的搜尋範圍。若直接將設計區域中每一個像素作為獨立設計變數，雖然可保留光學結構的完整資訊，但隨著設計區域解析度的提高，設計變數數量將會大幅增加，導致因子分解機模型訓練、QUBO 矩陣建構與模擬退火求解的計算成本也會大幅上升。

如第 3.2 節中所述，此篇論文已說明各編碼策略的相關理論基礎。接著，在本小節中將進一步介紹 Gaussian Upsampling Strategy、2D Fourier Integral Strategy 與 β -Variational

Autoencoder (β -VAE) Strategy 這三種編碼策略的具體實作方法以及其於因子分解機結合模擬退火架構中的運作流程。

4.2.1 Gaussian Upsampling Strategy

在前一節說明的因子分解機結合模擬退火架構中，設計變數的表示方式會直接影響搜尋空間大小與最佳化的效率。因此，本小節將介紹利用 Gaussian Upsampling Strategy 作為二維光學結構的編碼方法，此編碼策略以低維二元矩陣作為設計變數，並透過 Gaussian convolution、Tanh projection 與 MaterialGrid mapping 等步驟將其轉換為高解析度的物理結構，使最佳化過程能於較低維度的搜尋空間中進行，並同時維持結構邊界的平滑性與製程可行性。

4.2.1.1 Flowchart

Gaussian Upsampling Strategy 的整體流程如圖 20 所示，其中主要包含了低維設計變數重建、高斯卷積平滑、Tanh 投影以及 MaterialGrid 建立等四個步驟。




圖 20: 高斯上採樣 (Gaussian Upsampling) 流程圖。

在初始資料集建立階段，首先隨機產生 i 組低維二元結構。此研究設定每組結構由 $N \times N$ 的二元矩陣表示，因此每一組樣本包含 N^2 個二元設計變數。為了避免初始樣本產生過多沒有物理意義的隨機雜訊，會在隨機生成過程中加入平滑濾波處理，使初始結構具有較連續的幾何特徵。

首先，以 Gaussian kernel 對低維矩陣進行卷積運算，將原始二元分布轉換為連續密

度場，以降低像素化結構所造成的鋸齒狀邊界以及局部孤島或尖角，使材料分布具有空間連續性。

接著，利用 Tanh projection 將連續密度場重新映射為接近二元的材料分布。在這個步驟除了可以保留平滑邊界，也可以提高介面的清晰度，使生成出的光學結構具有可製造與可實現性。

完成 Gaussian Upsampling 編碼後，可以得到對應的高解析度密度矩陣。接著，所得的密度矩陣會丟給 MEEP 的 MaterialGrid 中，用來建立其對應的介電常數分佈，也就是正式把二維光學結構與材料分布建構出來。最後透過 MEEP(FDTD) 進行電磁模擬，就可以得到每組低維二元設計變數 x_i 所對應的光學性能與品質因子 y_i (Figure of Merit, FoM)。

在後續最佳化迭代過程中，因子分解機 (FM) 模型與模擬退火演算法皆於低維二元設計空間中進行搜尋。每當模擬退火採樣出新的候選解 x^* 時，這些候選解就會再次透過相同的 Gaussian Upsampling 流程轉換為高解析度結構，並輸入 MEEP 進行驗證。透過此機制，Gaussian Upsampling 在最佳化流程中扮演低維設計變數與實際物理結構之間的轉換橋樑。

相較於直接以高解析度像素作為設計變數，此方法可以大幅降低 QUBO 問題維度，同時透過高斯平滑與投影機限制結構邊界變化，使最佳化結果更符合實際製程需求。

4.2.1.2 Fabrication Constraints

雖然 Gaussian Upsampling 可將低維二元設計變數轉換為連續的幾何結構，但若未納入實際製程限制，最佳化的結果還是有可能會出現窄波導、尖角或孤島區域等難以製造的物理特徵。因此，本研究中利用 Gaussian filter 的空間平滑特性來控制結構的最小特徵尺寸 (Minimum Feature Size, MFS)，使生成之光學結構可以符合預期的製程限制。

由第 3.2.1 節中的公式(3.57)可知:

$$\sigma_{pix} \geq \frac{b_{fab}}{1.35d} \quad (4.4)$$

其中， b_{fab} 為製程允許的最小線寬 (Minimum Feature Size, MFS)， d 為單一網格 (pixel) 所對應的物理尺寸，而 σ_{pix} 為高斯濾波器的標準差。

為了避免 Gaussian Kernel 遭到截斷，高斯核卷積核的視窗大小必須滿足:

$$W \geq 6\sigma_{pix} + 1 \quad (4.5)$$

並且取奇數。

因此，假設設計區域為

$$5\mu m \times 5\mu m, \quad (4.6)$$

且其二元設計變數為 50×50 ，則我們可以計算出 d :

$$d = 100nm \quad (4.7)$$

若製成要求為:

$$b_{fab} = 100nm \quad (4.8)$$

則

$$\sigma_{pix} = \frac{150}{1.35 \times 100} \approx 1.11 \quad (4.9)$$

因此我們可以透過設定 $\sigma_{pix} = 1.11$ 以及 $W = 7$ 來滿足製程限制 $\geq 150nm$ 。

為方便實際參數設定，本研究整理不同製程限制與設計網格下所對應之 σ_{pix} 與 W ，如 Table 5 所示。

Grid size	Target MFS	σ_{pix}	W
50 nm	100 nm	1.48	9
50 nm	120 nm	1.78	11
100 nm	120 nm	0.89	5
100 nm	150 nm	1.11	7
100 nm	200 nm	1.48	9

TABLE 5: 不同製程限制下 Gaussian Filter 之設計參數對照表。

從 Table 5 可知，隨著目標最小線寬增加，所需的 Gaussian 標準差也必須提高，以增強平滑效果並抑制較小的幾何特徵。另一方面，由於過小的 Gaussian 標準差會使濾波器的平滑效果有限，並可能會降低對部分幾何特徵的約束能力，因此當 $\sigma_{pix} < 1$ 時，應該將 σ_{pix} 調整為 1。

4.2.2 2D Fourier Integral Strategy

4.2.3 β -Variational Autoencoder (β -VAE) Strategy

4.3 Mode Division Demultiplexer Optimization Results

4.4 Bend Waveguide Optimization Results

4.5 Waveguide Crossing Optimization Results

第五章、Conclusions

Write your conclusion here.



第六章、Performance Evaluation


In this section, 整理效能評估.


下面是 subfigure 的範例 (其實我個人不常用這個語法, 我都直接在繪圖工具上把圖片整合在一起 XD)



圖 21: Three simple graphs


References

- 
- [1] Meep Development Team, “Meep documentation,” <https://meep.readthedocs.io/>, 2026, accessed: 2026-06-29.
- [2] Y. Hao, *FDTD Modeling of Metamaterials: Theory and Applications*. Artech House, 2008.
- [3] S. J. Cox and D. C. Dobson, “Maximizing band gaps in two-dimensional photonic crystals,” *SIAM Journal on Applied Mathematics*, vol. 59, no. 6, pp. 2108–2120, 1999.
- [4] P. I. Borel, A. Harpøth, L. H. Frandsen, M. Kristensen, P. Shi, J. S. Jensen, and O. Sigmund, “Topology optimization and fabrication of photonic crystal structures,” *Optics Express*, vol. 12, no. 9, pp. 1996–2001, 2004.
- [5] J. S. Jensen and O. Sigmund, “Topology optimization for nano-photonics,” *Laser & Photonics Reviews*, vol. 5, no. 2, pp. 308–321, 2011.
- [6] C. M. Lalau-Keraly, S. Bhargava, O. D. Miller, and E. Yablonovitch, “Adjoint shape optimization applied to electromagnetic design,” *Optics Express*, vol. 21, no. 18, pp. 21 693–21 701, 2013.
- [7] A. Y. Piggott, J. Lu, K. G. Lagoudakis, J. Petykiewicz, T. M. Babinec, and J. Vučković, “Inverse design and demonstration of a compact and broadband on-chip wavelength demultiplexer,” *Nature Photonics*, vol. 9, no. 6, pp. 374–378, 2015.

- 
- [8] B. Shen, P. Wang, R. Polson, and R. Menon, “An integrated-nanophotonics polarization beamsplitter with $2.4 \times 2.4 \mu\text{m}^2$ footprint,” *Nature Photonics*, vol. 9, no. 6, pp. 378–382, 2015.
- [9] L. F. Frellsen, Y. Ding, O. Sigmund, and L. H. Frandsen, “Topology optimized mode multiplexing in silicon-on-insulator photonic wire waveguides,” *Optics Express*, vol. 24, no. 15, pp. 16 866–16 873, 2016.
- [10] A. Y. Piggott, J. Petykiewicz, L. Su, and J. Vučković, “Fabrication-constrained nanophotonic inverse design,” *Scientific Reports*, vol. 7, no. 1, p. 1786, 2017.
- [11] S. Molesky, Z. Lin, A. Y. Piggott, W. Jin, J. Vučković, and A. W. Rodriguez, “Inverse design in nanophotonics,” *Nature Photonics*, vol. 12, no. 11, pp. 659–670, 2018.
- [12] A. M. Hammond, A. Oskooi, S. G. Johnson, and S. E. Ralph, “Photonic topology optimization with semiconductor-foundry design-rule constraints,” *Optics Express*, vol. 29, no. 15, pp. 23 916–23 938, 2021.
- [13] Y.-C. Pao and J.-S. Wu, “Nano-focusing by topology optimization,” Master’s thesis, National Yang Ming Chiao Tung University, 2026.
- [14] S. Kirkpatrick, C. D. Gelatt, and M. P. Vecchi, “Optimization by simulated annealing,” *Science*, vol. 220, no. 4598, pp. 671–680, 1983.
- [15] T. Kadowaki and H. Nishimori, “Quantum annealing in the transverse ising model,” *Physical Review E*, vol. 58, no. 5, p. 5355, 1998.
- [16] S. Rendle, “Factorization machines,” in *2010 IEEE International Conference on Data Mining (ICDM)*, 2010, pp. 995–1000.

- [17] K. Kitai, J. Guo, S. Ju, S. Tanaka, K. Tsuda, J. Shiomi, and R. Tamura, “Designing meta-materials with quantum annealing and factorization machines,” *Physical Review Research*, vol. 2, no. 1, p. 013319, 2020.
- [18] T. Inoue, Y. Seki, S. Tanaka, N. Togawa, K. Ishizaki, and S. Noda, “Towards optimization of photonic-crystal surface-emitting lasers via quantum annealing,” *Optics Express*, vol. 30, no. 24, pp. 43 503–43 512, 2022.
- [19] C. Zhu, E. A. Bamidele, X. Shen, G. Zhu, and B. Li, “Machine learning aided design and optimization of thermal metamaterials,” *Chemical Reviews*, vol. 124, no. 7, pp. 4258–4331, 2024.
- [20] J.-J. Hu and J.-S. Wu, “Optical filter and other applications designed by factorization machines with quantum annealing,” Master’s thesis, National Yang Ming Chiao Tung University, 2025.
- [21] Y.-H. Chang and J.-S. Wu, “Quantum-compatible inverse design of superoscillatory lenses,” Master’s thesis, National Yang Ming Chiao Tung University, 2026.
- [22] B. S. Lazarov and O. Sigmund, “Filters in topology optimization based on helmholtz-type differential equations,” *International Journal for Numerical Methods in Engineering*, vol. 86, no. 6, pp. 765–781, 2011.
- [23] A. Odena, V. Dumoulin, and C. Olah, “Deconvolution and checkerboard artifacts,” *Distill*, vol. 1, no. 10, p. e3, 2016.
- [24] W. Shi, J. Caballero, F. Huszár, J. Totz, A. P. Aitken, R. Bishop, and Z. Wang, “Real-time single image and video super-resolution using an efficient sub-pixel convolutional

- neural network,” in *Proceedings of the IEEE conference on computer vision and pattern recognition (CVPR)*, 2016, pp. 1874–1883.
- [25] I. Higgins, L. Matthey, A. Pal, C. Burgess, X. Glorot, M. Botvinick, S. Mohamed, and A. Lerchner, “ β -VAE: Learning basic visual concepts with a constrained variational framework,” in *International Conference on Learning Representations (ICLR)*, 2017.
- [26] C. P. Burgess, I. Higgins, A. Pal, L. Matthey, N. Watters, G. Desjardins, and A. Lerchner, “Understanding disentangling in β -VAE,” *arXiv preprint arXiv:1804.03599*, 2018.
- [27] W. Ma, F. Cheng, Y. Xu, Q. Wen, and Y. Liu, “Probabilistic representation and inverse design of metamaterials based on a deep generative model with semi-supervised learning strategy,” *Advanced Materials*, vol. 31, no. 35, p. 1901111, 2019.
- [28] R. Zhang, “Making convolutional networks shift-invariant again,” in *International Conference on Machine Learning (ICML)*, 2019, pp. 7324–7334.
- [29] Z. Li, N. Kovachki, K. Azizzadenesheli, B. Liu, K. Bhattacharya, A. Stuart, and A. Anandkumar, “Fourier neural operator for parametric partial differential equations,” in *ICLR*, 2020.
- [30] Z. A. Kudyshev, A. V. Kildishev, V. M. Shalaev, and A. Boltasseva, “Machine-learning-assisted global optimization of photonic devices,” *Nanophotonics*, vol. 10, no. 1, pp. 371–383, 2021.
- [31] T. Karras, M. Aittala, S. Laine, E. Härkönen, J. Hellsten, J. Lehtinen, and T. Aila, “Alias-free generative adversarial networks,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 34, 2021, pp. 852–863.

- 
- [32] A. Yariv and P. Yeh, *Photonics: Optical Electronics in Modern Communications*, 6th ed. Oxford, UK: Oxford University Press, 2007.
- [33] M. Heiblum and J. H. Harris, “Analysis of curved optical waveguides by conformal transformation,” *IEEE Journal of Quantum Electronics*, vol. 11, no. 2, pp. 75–83, Feb. 1975.
- [34] L. Chrostowski and M. Hochberg, *Silicon Photonics Design: From Devices to Systems*, 1st ed. Cambridge, UK: Cambridge University Press, 2015.
- [35] A. F. Oskooi, D. Roundy, M. Ibanescu, P. A. Bermel, J. D. Joannopoulos, and S. G. Johnson, “Meep: A flexible free-software package for electromagnetic simulations by the fdtd method,” *Computer Physics Communications*, vol. 181, no. 3, pp. 687–702, 2010.
- [36] B. A. Wilson, Z. A. Kudyshev, A. V. Kildishev, S. Kais, V. M. Shalaev, and A. Boltasseva, “Machine learning framework for quantum sampling of highly constrained, continuous optimization problems,” *Applied Physics Reviews*, vol. 8, no. 4, Dec. 2021. [Online]. Available: <http://dx.doi.org/10.1063/5.0060481>
- [37] D-Wave Systems, “Ocean sdk documentation,” <https://docs.ocean.dwavesys.com/>, 2026, accessed: 2026-07-05.

第七章、Appendix 附錄

本附錄整理撰寫論文時常見的排版與語法注意事項，供大家撰寫與校稿時參考，請記得看 latex 的語法。(此段落主要由 ChatGPT 撰寫整理 XD)

文字與標點

- 英文引號請使用成對反引號與直引號：`"text"` → `"text"`。
- 破折號 (dash) 有三種：`-` (連字號，如 *pre-trained*)、`-` (範圍，如 10–20)、`—` (句中強調，如 the result—as expected—was correct)。
- 省略號請使用 `\ldots` 而非三個句點：A, B, C..., Z。
- 數值與單位間需留不換行空白：10 km, 30°C。
- 中英文混排時，中文與英文之間宜留一半形空白，例如：中文 English 中文。

數學與符號

- 數學變數自動為斜體，單位或文字常數須使用 `\mathrm{}` 或 `\text{}`，如 $v = 10 \text{ m/s}$ 。
- 三角函數、極值運算等應以數學命令表示： $\sin \theta$, $\max(x, y)$ 。
- 向量或矩陣可用粗體： $\mathbf{x} = [x_1, x_2]^\top$ 。
- 多行方程式請使用 `align` 環境，勿以多個 `equation` 拆寫。

圖表與引用

- 圖片標題 (caption) 置於圖下方
- 表格標題置於表上方。
- 參照圖表時請使用 `\ref{}` 或 `\autoref{}`，勿手動輸入編號。

例：As shown in Fig. ??.

- 表格建議使用 booktabs 套件：`\toprule`、`\midrule`、`\bottomrule`。

文獻與引用

- 文獻引用使用 `\cite{key}` 或 `\parencite{key}`。
- 多篇同時引用可寫為 `\cite{a,b,c} → [1-3]`。
- 特殊大小寫 (如 GPU, LaTeX) 須以大括號保留：`{GPU}`。